UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Reconhecimento de Emoção da Fala utilizando Aprendizado Profundo e Transformada *Wavelet*

Rafael Greca Vieira

Monografia - MBA em Inteligência Artificial e Big Data

ICMC USP
SÃO CARLOS

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Rafael Greca Vieira

Reconhecimento de Emoção da Fala utilizando Aprendizado Profundo e Transformada *Wavelet*

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientadora: Profa. Dra. Alessandra Alaniz Macedo

Versão original

São Carlos

2023

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi
e Seção Técnica de Informática, ICMC/USP,
com os dados inseridos pelo(a) autor(a)

G789r

Greca Vieira, Rafael
Reconhecimento de Emoção da Fala utilizando Aprendizado Profundo e Transformada Wavelet / Rafael Greca Vieira; orientadora Alessandra Alaniz Macedo. -- São Carlos, 2023.
69 p.

Trabalho de conclusão de curso (MBA em Inteligência Artificial e Big Data) -- Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2023.

1. Aprendizado Profundo. 2. Transforma Discreta Wavelet. 3. Reconhecimento de Emoção da Fala. 4. Rede Neural Convolucional. 5. Inteligência Artificial. I. Alaniz Macedo, Alessandra, orient. II. Título.

Bibliotecários responsáveis pela estrutura de catalogação da publicação de acordo com a AACR2:
Gláucia Maria Saia Cristianini - CRB - 8/4938
Juliana de Souza Moraes - CRB - 8/6176

Rafael Greca Vieira

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Profa. Dra. Alessandra Alaniz Macedo

Original version

São Carlos

2023

Este trabalho é dedicado ao meu amigo e ex-colega de graduação Josias Vieira Varela (in memoriam) e a toda comunidade científica de inteligência artificial.

AGRADECIMENTOS

Agradeço aos meus pais, Sérgio e Cristiane, e a minha irmã, Isabela, por todo apoio, confiança e incentivo depositado a mim.

A minha namorada, Ana Julia Diniz Mesquita, por todo amor, apoio, paciência, incentivo e companheirismo.

Aos professores do Instituto de Ciências Matemáticas e de Computação da Universidade de São Paulo — Campus São Carlos por todo conhecimento adquirido. Em especial à Profa. Dra. Alessandra Alaniz Macedo por aceitar me orientar e pela paciência ao longo do desenvolvimento desse trabalho de conclusão.

Aos colegas de turma do MBA que fizeram parte da minha trajetória por todo conhecimento compartilhado.

"A ciência não é tudo, mas é muito bonita."

J. Robert Oppenheimer

RESUMO

VIEIRA, R.G **Reconhecimento de Emoção da Fala utilizando Aprendizado Profundo e Transformada *Wavelet***. 2023. 69p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2023.

Com a evolução das máquinas no século passado, computadores e celulares móveis mais modernos foram sendo desenvolvidos e aprimorados. Concomitantemente, o surgimento e a evolução da internet trouxeram a possibilidade de pessoas de todo canto do mundo comunicarem entre si, por meio de ligação telefônica, mensagem de texto ou vídeo. Por conseguinte, a vasta quantidade disponível desses tipos de dados resultou na expansão e evolução da área de Processamento de Língua Natural. Este trabalho objetiva desenvolver um modelo de aprendizado profundo em conjunto com a técnica de Transformada *Wavelet* na tarefa de reconhecimento de emoção da fala por meio da utilização da base de dados CORAA, validando a solução desenvolvida nas bases EMODB, RAVDESS e SAVEE. A solução proposta é composta por um modelo cuja arquitetura é baseada em uma rede neural pré-treinada em áudios, Transformada Discreta *Wavelet* e a técnica *SpecAugment* para realizar *data augmentation* nos dados. Os resultados encontrados apontam que a utilização dessas técnicas em conjunto é promissora, pois foi possível conquistar bons desempenhos nas diferentes bases de dados. Ademais, também é possível afirmar que a solução desenvolvida é agnóstica, podendo ser utilizada em conjuntos de dados de diferentes idiomas e que são compostas por diferentes tipos de emoções.

Palavras-chave: Aprendizado Profundo. Transformada Discreta *Wavelet*. Reconhecimento de Emoção da Fala. Rede Neural Convolucional. Inteligência Artificial. Análise de Sentimentos.

ABSTRACT

VIEIRA, R.G **Speech Emotion Recognition using Deep Learning and Wavelet Transform**. 2023. 69p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2023.

As technology advanced over the last century, modern computers and smartphones have been developed and enhanced. Simultaneously, the rise and evolution of the Internet have opened up possibilities for global communication through phone calls, text messages, and video chats. Consequently, the vast amount of available data of this nature has led to the growth and progression of the field of Natural Language Processing (NLP). This study aims to create a deep learning model in conjunction with the Wavelet Transform technique for the task of speech emotion recognition, using the CORAA database for training and validating the solution on the EMODB, RAVDESS, and SAVEE databases. Our methodology involves a model architecture based on a neural network pretrained on audio data, incorporating the Discrete Wavelet Transform and the SpecAugment technique for data augmentation. The results demonstrate the promise of combining these techniques, as it was possible to achieve strong performance across different databases. Additionally, it is worth noting that the developed solution is language-agnostic and can be applied to datasets in various languages containing different types of emotions.

Keywords: Deep Learning. Discrete Wavelet Transform. Speech Emotion Recognition. Convolutional Neural Network. Artificial Intelligence. Sentiment Analysis.

LISTA DE FIGURAS

Figura 1 – Funcionamento dos filtros da camada de convolução. 29
Figura 2 – Funcionamento da camada de *pooling*. 30
Figura 3 – Arquitetura de uma RNC. 30
Figura 4 – Comparação de um sinal estacionário no domínio do tempo e no domínio da frequência. 32
Figura 5 – Comparação de um sinal não-estacionário no domínio do tempo e no domínio da frequência. 33
Figura 6 – Comparação da aplicação da TFCT em um sinal estacionário e não-estacionário. 34
Figura 7 – Exemplos de diferentes famílias de *Wavelet*. 34
Figura 8 – Exemplo do resultado da TW. 35
Figura 9 – Comparação entre a TDW e TPW. 35
Figura 10 – Exemplo de ROC-AUC. 37
Figura 11 – Resultado da primeira triagem realizada nos trabalhos. 41
Figura 12 – Quantidade de trabalhos rejeitados por critério de inclusão. 41
Figura 13 – Quantidade de trabalhos rejeitados por critério de avaliação. 43
Figura 14 – Fluxograma das etapas de desenvolvimento do trabalho. 45
Figura 15 – Distribuição do conjunto de dados CORAA. 46
Figura 16 – Análise qualitativa do conjunto de dados da CORAA. 46
Figura 17 – Distribuição do conjunto de dados EMODB. 47
Figura 18 – Distribuição do conjunto de dados RAVDESS. 48
Figura 19 – Distribuição do conjunto de dados SAVEE. 48
Figura 20 – Exemplo de utilização da técnica *SpecAugment*. 50
Figura 21 – Arquitetura do modelo RNAP RNC 6. 51
Figura 22 – Arquitetura do modelo RNAP RNC 10. 51
Figura 23 – Arquitetura do modelo RNC. 52
Figura 24 – Exemplos do experimento qualitativo com algoritmos de detecção de atividade de voz. 54
Figura 25 – Exemplo das diferentes ordens de execução de extração de características. 55
Figura 26 – Matriz de confusão do modelo nas diferentes bases de dados. 59

LISTA DE TABELAS

Tabela 1 – Critérios de inclusão e exclusão dos trabalhos. 40
Tabela 2 – Resultado inicial obtido na busca em cada biblioteca. 40
Tabela 3 – Resultado do mapeamento sistemático. 42
Tabela 4 – Opções das variações utilizadas nos experimentos. 55
Tabela 5 – Resultado dos experimentos com o modelo RNAP CNN6. 56
Tabela 6 – Resultado dos experimentos com o modelo RNAP CNN10. 57
Tabela 7 – Resultado dos experimentos com o modelo RNC. 57
Tabela 8 – Resultado dos experimentos com diferentes técnicas de *data augmentation*. 58
Tabela 9 – Resultados do melhor modelo nas bases de dados. 58
Tabela 10 – Comparação dos resultados com outros trabalhos da literatura. 61

LISTA DE ABREVIATURAS E SIGLAS

PLN	Processamento de Língua Natural
RNA	Rede Neural Artificial
RNC	Rede Neural Convolucional
LSTM	*Long Short-Term Memory*
SVM	*Support Vector Machine*
KNN	*k-Nearest Neighbor*
NB	*Naive Bayes*
RNAP	Rede Neural de Áudio Pré-treinada
MFCC	*Mel-Frequency Cepstral Coefficients*
TCW	Transformada Contínua *Wavelet*
TDW	Transformada Discreta *Wavelet*
TPW	Transformada de Pacotes *Wavelet*
TF	Transformada de Fourier
TFCT	Transformada de Fourier em Curto Tempo
TW	Transformada *Wavelet*
VP	Verdadeiro Positivo
FP	Falso Positivo
VN	Verdadeiro Negativo
FN	Falso Negativo
TVP	Taxa de Verdadeiro Positivo
TFP	Taxa de Falso Positivo
PROPOR	Conferência Internacional de Processamento Computacional da Língua Portuguesa
EMODB	*Berlin Emotional Database*

RAVDESS	*Ryerson Audio-Visual Database of Emotional Speech and Song*
SAVEE	*Survey Audio-Visual Expressed Emotion*

SUMÁRIO

1 INTRODUÇÃO . . . 25

2 FUNDAMENTAÇÃO TEÓRICA . . . 27
2.1 Aprendizado de Máquina . . . 27
2.2 Aprendizado Profundo . . . 28
2.2.1 RNC . . . 29
2.3 Reconhecimento de Emoção da Fala . . . 30
2.4 TW . . . 31
2.5 Métricas de Avaliação . . . 36
2.5.1 *F1-Score* . . . 36
2.5.2 Acurácia . . . 36
2.5.3 ROC-AUC . . . 37

3 TRABALHOS RELACIONADOS . . . 39

4 MATERIAIS E MÉTODOS . . . 45
4.1 Bases de Dados . . . 45
4.1.1 CORAA . . . 45
4.1.2 EMODB . . . 46
4.1.3 RAVDESS . . . 47
4.1.4 SAVEE . . . 48
4.2 Ambiente de Execução . . . 49
4.3 Ferramentas Utilizadas . . . 49
4.4 Processamento dos Dados . . . 49
4.5 Modelos de Classificação . . . 50
4.5.1 RNAP RNC 6 . . . 51
4.5.2 RNAP RNC 10 . . . 51
4.5.3 RNC . . . 52
4.6 Avaliação do Modelo . . . 52

5 EXPERIMENTOS E RESULTADOS . . . 53

6 CONCLUSÃO . . . 63

REFERÊNCIAS . . . 65

1 INTRODUÇÃO

A origem da linguagem é uma questão discutida de forma bem intensa até hoje entre os pesquisadores das mais diversas áreas. (DARWIN, 1888) acreditava que a linguagem surgiu da imitação dos sons naturais, dos animais e do choro dos homens; já (CHOMSKY, 1987) afirmava que ela surgiu da mutação das células do cérebro; por outro lado, outros acreditam que o gesto antecedeu a linguagem ou que se originaram como um meio de comunicação (ARAKI, 2018). Independente da sua origem, a evolução da fala foi fundamental para o desenvolvimento da vida social e da cultura, sendo de suma importância na evolução da espécie humana (FITCH, 2000).

A invenção do primeiro telefone, que aconteceu no final do século XIX por Alexander Graham Bell e Thomas Watson, possibilitou a transmissão de sons por meio de sinais elétricos de um aparelho para outro, possibilitando as pessoas a comunicarem entre si de diferentes localizações. Esse marco histórico influenciou no surgimento de novas invenções no século seguinte, como o aprimoramento do telefone e a invenção do rádio. A grande evolução das máquinas no século XX resultou no desenvolvimento de computadores e de celulares móveis mais modernos. Além disso, concomitante com o surgimento e evolução da internet no final do século, possibilitou que as pessoas pudessem se comunicar entre si de todo canto do mundo, seja por meio de mensagens de texto ou áudio.

Devido à vasta quantidade de dados gerados diariamente de diferentes fontes na internet — como redes sociais, fóruns e outros tipos de sites — foi de grande necessidade uma evolução tecnológica e do poder computacional para suportar armazenar e trabalhar com essa abundância de dados — disponíveis nos mais variados formatos, como: tabulado, imagem, texto, geoespacial ou áudio.

O Processamento de Língua Natural (PLN) é uma subárea da ciência da computação que visa estudar, aprender e construir conteúdo com linguagem humana (HIRSCHBERG; MANNING, 2015) utilizando dados linguísticos, como áudio — abordado neste trabalho — e texto. Existem diversos campos de estudo na área de PLN, dentre eles está o reconhecimento de emoção da fala.

A área de reconhecimento de emoção visa identificar o estado emocional de uma pessoa, podendo ser exteriorizada por meio de um texto, gesto ou voz (KONAR; CHAKRABORTY, 2015). O campo de estudo que lida com essas manifestações em textos é o de análise de sentimentos, o que lida com gesto — mais precisamente as expressões faciais — é o de reconhecimento de emoção facial e, por fim, o que lida com voz é o reconhecimento de emoção da fala, tema abordado nesse trabalho.

A principal motivação deste trabalho é investir e propor soluções na área de

reconhecimento de emoção devido à sua ampla possibilidade de aplicações nos mais diversos setores, sendo alguns deles: auxílio na detecção de mentiras, sistema de tutoria inteligente personalizado para cada usuário, auxílio em diagnósticos feitos por terapeutas da fala (RAMAKRISHNAN; EMARY, 2013) e como uma ferramenta auxiliar para *softwares* de tecnologia assistiva — como o SofiaFala (RISSATO; MACEDO, 2021), utilizado para aprimorar a comunicação verbal de crianças com síndrome de *Down*.

O objetivo principal deste trabalho é utilizar a técnica de aprendizado profundo no reconhecimento de emoção da fala. Para atacar essa tarefa foi utilizada a técnica de Transformada *Wavelet* (TW), considerada um avanço na área de análise matemática e melhoria da Transformada de Fourier em Curto Tempo (TFCT) — método padrão utilizado nas funções de transformação do domínio do tempo para o domínio da frequência (GUO *et al.*, 2022). Além da sua utilização na área de reconhecimento de emoção da fala, a TW também é utilizada em outras aplicações, sendo algumas delas: outros campos de estudo do processamento tradicional de sinais e em áreas de processamento de imagens e problemas de otimização (GUO *et al.*, 2022). Para alcançar este objetivo foram utilizados os conjuntos de dados da CORAA (MARCACINI; JUNIOR; CASANOVA, 2022), proposto no evento Conferência Internacional de Processamento Computacional da Língua Portuguesa (PROPOR) sediado na Universidade de Fortaleza no ano de 2022, *Berlin Emotional Database* (EMODB) (BURKHARDT *et al.*, 2005), *Survey Audio-Visual Expressed Emotion* (SAVEE) (VLASENKO *et al.*, 2007) e *Ryerson Audio-Visual Database of Emotional Speech and Song* (RAVDESS) (LIVINGSTONE; RUSSO, 2018). O modelo de aprendizado profundo desenvolvido conquistou bons resultados em todos os conjuntos de dados, com aproximadamente 0.566 de *F1-Score macro* na base da CORAA, 0.804, 0.578 e 0.604 de acurácia nas bases EMODB, RAVDESS e SAVEE, respectivamente.

Este trabalho está dividido da seguinte maneira, além deste capítulo introdutório: Capítulo 2 apresenta os conceitos teóricos acerca do tema; Capítulo 3 apresenta os trabalhos da literatura relacionados; Capítulo 4 aborda a metodologia escolhida, as bases de dados utilizadas, apresenta informações a respeito da etapa de pré-processamento dos dados e o ambiente de execução dos modelos; Capítulo 5 descreve os experimentos que foram realizados e os resultados obtidos; Capítulo 6 levanta as principais conclusões a respeito do trabalho desenvolvido, apresenta suas limitações e propõe possíveis trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo visa apresentar os conceitos teóricos de suporte a este trabalho e está organizado da seguinte forma: será discorrido sobre aprendizado de máquina na Seção 2.1, aprendizado profundo na Seção 2.2, reconhecimento de emoção da fala na Seção 2.3, TW na Seção 2.4 e, por fim, as métricas utilizadas neste trabalho na Seção 2.5.

2.1 Aprendizado de Máquina

Os primeiros produtos de inteligência artificial surgiram como um sistema utilizado para a tomada de decisões utilizando uma base de conhecimentos e regras criadas por um ser humano especialista na área de atuação do sistema. Esse tipo de sistema — também chamado de sistema especialista ou baseado em conhecimento — ainda é utilizado atualmente e possui aplicações em diversas áreas, sendo algumas delas: agricultura, medicina, engenharia, química e sistemas de computadores (GOMES, 2010).

O tipo de sistema mencionado anteriormente apresenta algumas dificuldades e empecilhos, como a complexidade em gerar conhecimentos que representem fielmente os problemas da realidade e a dependência de gerar a base de conhecimento e regras manualmente (GOODFELLOW; BENGIO; COURVILLE, 2016). Por conseguinte, foi necessária a criação de um sistema de inteligência artificial que possuísse a habilidade, chamada de aprendizado de máquina, de conseguir adquirir seu próprio conhecimento por meio da extração de padrões de uma base de dados brutos (GOODFELLOW; BENGIO; COURVILLE, 2016).

O conhecimento descoberto pelo modelo de aprendizado de máquina é obtido durante a etapa de aprendizagem, também chamada de etapa de treinamento. O principal objetivo desse processo é fazer com que o modelo aprenda e que esse conhecimento adquirido reproduza os resultados esperados para os dados conhecidos, almejando alcançar o melhor desempenho possível e, ao mesmo tempo, conseguir generalizar esse conhecimento para dados que ainda não foram vistos, sem degradar o seu desempenho.

De um ponto de vista amplo, os algoritmos de aprendizado de máquina podem ser categorizados conforme o seu processo de treinamento, podendo ser — de um modo mais amplo — supervisionado e não-supervisionado (GOODFELLOW; BENGIO; COURVILLE, 2016). O algoritmo supervisionado, utilizado neste trabalho, usufrui de dados associados com suas respectivas classes, já o não-supervisionado utiliza dados cujas classes não são conhecidas, aprendendo mediante a descoberta de padrões ocultos contidos nos dados.

O modelo de aprendizado de máquina também pode ser categorizado segundo o tipo de tarefa que será solucionada, pode ser de classificação ou regressão. Se a saída do

modelo é um valor discreto a tarefa é de classificação, porém se for um valor contínuo a tarefa é de regressão (ZHOU, 2021). Caso seja classificação e só exista duas classes possíveis, também pode ser chamado de classificação binária. Caso contrário, é chamado de classificação de múltiplas classes. A tarefa abordada nesse trabalho é uma classificação de múltiplas classes.

A utilização dos algoritmos de aprendizado de máquina está cada vez mais presente em inúmeras áreas do conhecimento, não limitando em apenas reconhecimento de emoção da fala, devido aos resultados promissores que estão sendo alcançados. Alguns dos algoritmos encontrados na literatura que são utilizados na tarefa de reconhecimento de emoções da fala são: Modelo de Mistura Gaussiana, Modelo Oculto de Markov, *Support Vector Machine* (SVM), Árvores de Decisão, *Naive Bayes* (NB) e *k-Nearest Neighbor* (KNN) (WANI *et al.*, 2021).

2.2 Aprendizado Profundo

Os algoritmos de aprendizado profundo surgiram da limitação dos algoritmos de aprendizado de máquina em conseguir extrair informações complexas dos dados. Essa capacidade que os modelos de aprendizado profundo possuem de conseguir adquirir conhecimento com um alto nível de representação por meio de uma vasta quantidade de dados é dada pela sua arquitetura constituída de múltiplas camadas de processamento (LECUN; BENGIO; HINTON, 2015).

Apesar da sua grande capacidade de extrair informações de um conjunto de dados e dos resultados promissores obtidos nas mais diversas áreas, os algoritmos de aprendizado profundo também possuem limitações e pontos negativos, como: problemas de viés e desvio nos dados, requer uma escolha cautelosa dentre várias opções de implementação e é necessário ter um grande conhecimento teórico dos modelos, além de serem modelos complexos (JANIESCH; ZSCHECH; HEINRICH, 2021). Os algoritmos de aprendizado de máquina também superam em relação a poder computacional, pois demoram menos para treinar e necessitam de menos memória — por serem modelos com arquiteturas menores comparadas aos de aprendizado profundo.

Além dos pontos levantados anteriormente, esses modelos de aprendizado profundo possuem um desempenho melhor que os de aprendizado de máquina quando são utilizados com grandes volumes de dados de grande dimensão. Caso a quantidade de dados seja limitada ou possuam poucas dimensões, os modelos de aprendizado de máquina são mais vantajosos (JANIESCH; ZSCHECH; HEINRICH, 2021).

O uso de algoritmos de aprendizado profundo tem obtido resultados promissores em diversos campos de estudo da compreensão da linguagem natural (LECUN; BENGIO; HINTON, 2015). Alguns dos algoritmos encontrados na literatura utilizados na tarefa de

reconhecimento de emoção da fala são: Rede Neural Convolucional (RNC), *Long Short-Term Memory* (LSTM), Rede Neural Recorrente, Rede Neural Convolucional baseada em Atenção, Rede Neural Profunda, Rede de Função de Base Radial (WANI *et al.*, 2021), além de variações dos modelos citados ou a utilização de mais de um modelo em conjunto. Nesse trabalho, serão utilizados modelos de aprendizado profundo com arquiteturas baseadas em RNC.

2.2.1 RNC

A RNC é uma rede neural especializada em processar dados de formato semelhante a uma grade — como, por exemplo, uma imagem ou dados temporais (GOODFELLOW; BENGIO; COURVILLE, 2016). Para a utilização de áudios nessa rede neural, esses dados são representados de forma visual por meio de espectrogramas, espectrogramas na escala mel ou outras técnicas. A arquitetura da RNC é composta por três tipos de camadas: a de convolução, a *pooling* e a densa (O'SHEA; NASH, 2015).

A camada de convolução é essencial para o funcionamento da RNC, pois nela são utilizados filtros — também chamados de *kernels* — de pequena dimensionalidade que são aprendidos ao logo do treinamento da rede e deslocados por toda a profundidade dos dados de entrada enquanto extrai características — conforme é possível visualizar na Figura 1 — formando um mapa de ativações (O'SHEA; NASH, 2015).

Figura 1 – Funcionamento dos filtros da camada de convolução.

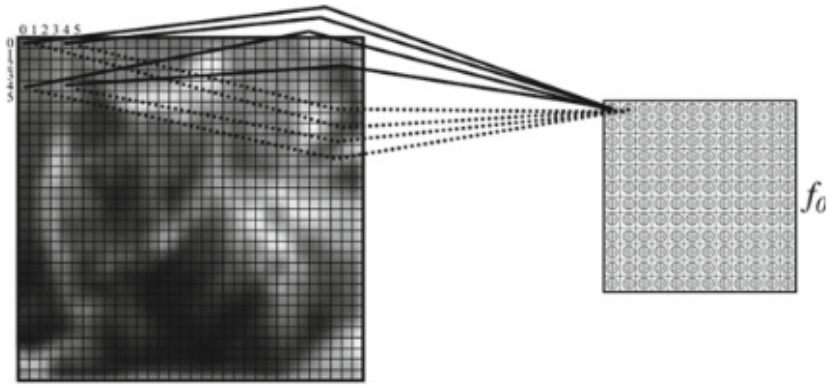

Fonte: (AGHDAM; HERAVI *et al.*, 2017).

Já a camada de *pooling*, conforme demonstrado na Figura 2, visa reduzir a dimensionalidade da saída da camada anterior. Apesar dessa técnica não preservar a informação espacial, ela ajuda a reduzir a complexidade das camadas posteriores (ALBAWI; MOHAMMED; AL-ZAWI, 2017), tornando as representações praticamente invariantes a pequenas translações dos dados, podendo melhorar bastante a eficiência da rede neural (GOODFELLOW; BENGIO; COURVILLE, 2016).

Figura 2 – Funcionamento da camada de *pooling*.

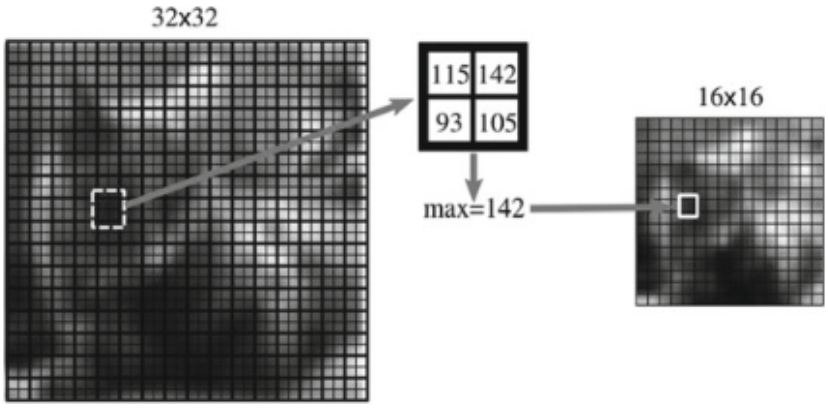

Fonte: (AGHDAM; HERAVI *et al.*, 2017).

Por fim, a camada densa possui todos os neurônios conectados com todos os nós da camada anterior e da posterior — similar a Rede Neural Artificial (RNA) tradicional — e, como consequência e principal desvantagem dessa camada, é composta por hiper-parâmetros de grande complexidade computacional (ALBAWI; MOHAMMED; AL-ZAWI, 2017). Uma visão completa da arquitetura de uma RNC pode ser vista na Figura 3.

Figura 3 – Arquitetura de uma RNC.

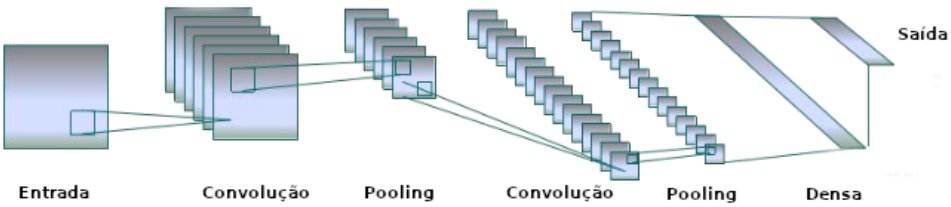

Fonte: Adaptado de (LIU *et al.*, 2015).

2.3 Reconhecimento de Emoção da Fala

O PLN, também conhecido como computação linguística, é uma das subáreas da ciência da computação que visa estudar, aprender e construir conteúdo com linguagem humana por meio da utilização de técnicas computacionais (HIRSCHBERG; MANNING, 2015). Dentro dessa subárea existem vários campos de estudo diferentes, sendo alguns deles: a tradução automática, análise de sentimentos em texto, sistemas de diálogos falados e reconhecimento de emoções da fala — tema abordado nesse trabalho.

A emoção representa o processo dos pensamentos e do estado psicológico da mente humana, tendo atraído cada vez mais pesquisadores interessados em determinar a emoção de um tema por meio da sua manifestação — seja por meio da voz, da face ou gesto do corpo (KONAR; CHAKRABORTY, 2015). O reconhecimento de emoção da fala utiliza

sinais de áudio brutos ou de forma visual — como por meio de espectrogramas, por exemplo — para o reconhecimento de emoções (LALITHA *et al.*, 2015).

As emoções a serem identificadas dependem segundo a base de dados utilizada, podendo ser categorizadas de diversas maneiras: binária, se ocorre alguma emoção ou não; múltiplas classes, como a não ocorrência de emoções (neutro), emoção positiva ou negativa. Uma classificação com múltiplas classes não está limitada a apenas três classes, sendo mais comum encontrar classes que estejam associadas com as emoções básicas ou com um conjunto delas. Existem diversas opiniões diferentes entre pesquisadores e estudiosos da área a respeito de quais são essas emoções básicas, entretanto, neste trabalho serão utilizadas — pelo menos algumas delas — as emoções definidas por (PLUTCHIK, 1980), sendo elas: medo, raiva, alegria, tristeza, aceitação, surpresa, expectativa e nojo.

Os conjuntos de dados utilizados na tarefa de classificação e reconhecimento de emoção da fala podem ser rotulados em três classes: fala espontânea, atuada ou eliciada (WANI *et al.*, 2021). As bases de dados compostas de fala espontânea englobam a forma mais autêntica e natural de como as emoções ocorrem, as bases compostas de fala atuada são geralmente gravadas por atores conforme o tipo de emoção e as bases compostas por falas eliciadas compreendem emoções incitadas por meio da indução de determinados sentimentos (WANI *et al.*, 2021).

A área de reconhecimento de emoção da fala possui uma vasta gama de aplicações no mundo real, principalmente no setor de interação humano-computador. Algumas dessas aplicações são: auxílio na detecção de mentiras, sistema de tutoria inteligente personalizada para cada usuário, auxílio em diagnósticos feitos por terapeutas da fala, interação mais natural de robôs, monitoramento de chamadas em canais de atendimento e de ligações em bancos (RAMAKRISHNAN; EMARY, 2013).

A tarefa de reconhecimento de emoção da fala pode ser atacada utilizando diversas características diferentes extraídas a partir dos áudios, sendo algumas delas: *Mel-Frequency Cepstral Coefficients* (MFCC), utilizada por (SCARANTI *et al.*, 2022) e (ISSA; DEMIRCI; YAZICI, 2020); TFCT, utilizada por (LIM; JANG; LEE, 2016); espectrograma, utilizada por (SCARANTI *et al.*, 2022) e (BADSHAH *et al.*, 2017); espectrograma na escala mel, utilizada por (GAUY; FINGER, 2022) e (ISSA; DEMIRCI; YAZICI, 2020); características de prosódia (como a amplitude máxima, tempo de silêncio, duração do áudio, volume, dentre outras), utilizada por (SCARANTI *et al.*, 2022) e (PERIN; MATSUBARA, 2022); TW, utilizada neste trabalho.

2.4 TW

A Transformada de Fourier (TF) é uma das técnicas mais utilizadas para transformar o áudio do domínio do tempo para o da frequência (BRACEWELL; BRACEWELL, 1986),

possibilitando a utilização de técnicas que conseguem extrair informações com um maior nível de profundidade — como espectrograma, espectrograma na escala mel e MFCC. Na Figura 4 é possível observar um sinal estacionário — cujas frequências são observadas durante todo o sinal — representado no domínio do tempo e no domínio da frequência, após a aplicação da TF. Nela, é possível observar um grande problema dessa transformada: não é possível identificar em qual momento do tempo cada frequência ocorre. Quando a TF é aplicada em um sinal não-estacionário com as mesmas frequências do sinal da Figura 4, demonstrado na Figura 5, esse problema fica ainda mais visível, já que ambos tiveram praticamente os mesmos resultados. Em decorrência disso, surgiu a TFCT como aprimoramento da tradicional TF.

Figura 4 – Comparação de um sinal estacionário no domínio do tempo e no domínio da frequência.

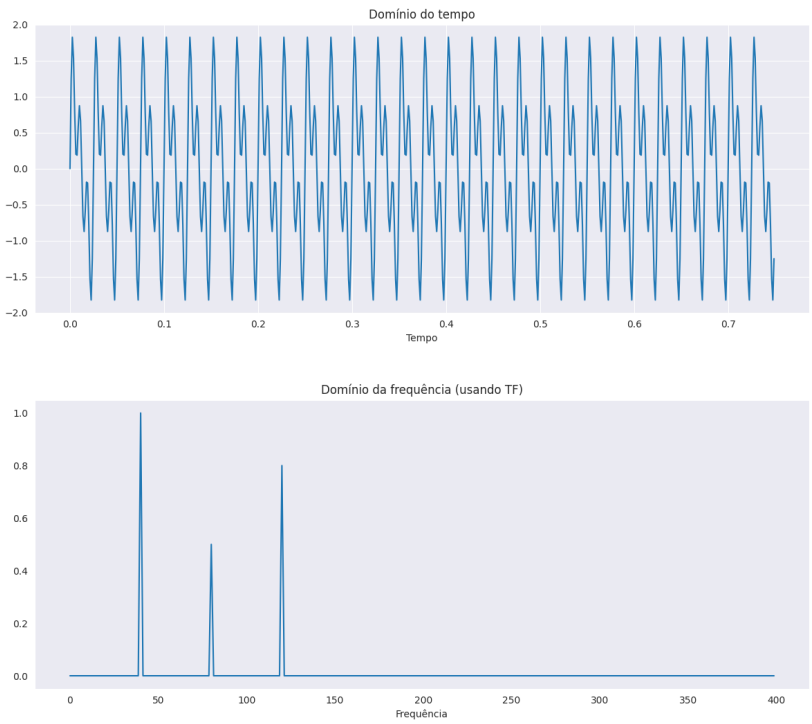

Fonte: Elaboração própria (2023).

Figura 5 – Comparação de um sinal não-estacionário no domínio do tempo e no domínio da frequência.

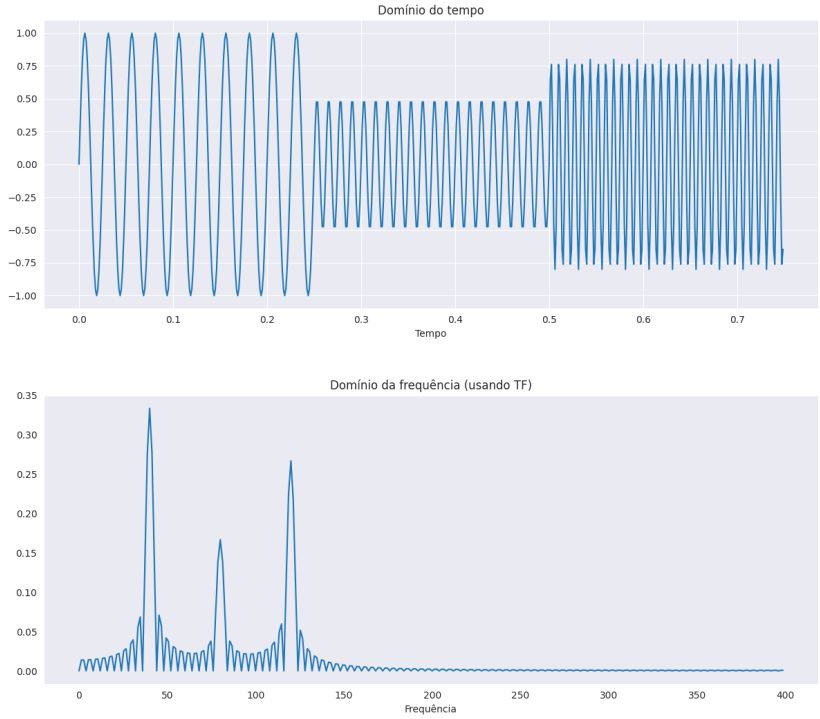

Fonte: Elaboração própria (2023).

A TFCT divide o sinal em janelas de tamanho fixo — assumindo que o sinal presente em cada janela é estacionário — e aplica a TF em cada uma delas, obtendo uma representação do domínio tempo-frequência (POLIKAR *et al.*, 1996). A TFCT foi aplicada no sinal estático e não-estático representados na Figura 4 e 5, respectivamente, e o resultado pode ser visto na Figura 6. Nela, é factível observar que agora pode ser identificado em que momento do tempo do sinal cada frequência ocorre. Porém, o Princípio da Incerteza de Heisenberg afirma que não é possível saber com exatidão a representação do sinal no domínio tempo-frequência, apenas a faixa de frequência que está presente em um determinado intervalo de tempo (POLIKAR *et al.*, 1996). A TW surgiu como uma alternativa para contornar esse problema.

Figura 6 – Comparação da aplicação da TFCT em um sinal estacionário e não-estacionário.

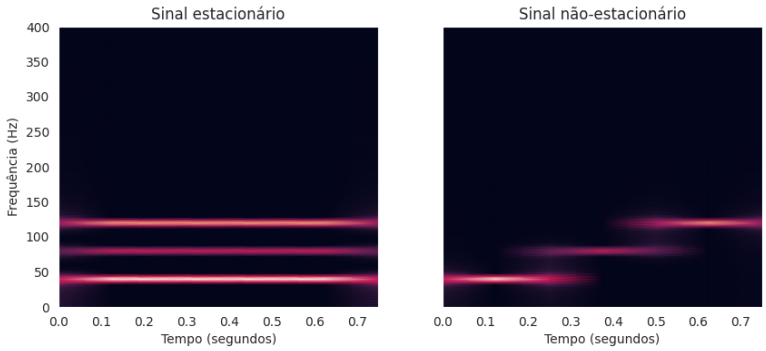

Fonte: Elaboração própria (2023).

A TW pode ser vista como uma melhoria da TF, uma vez que ela consegue decompor sinais complexos — como fala, música e imagem — em formas elementares representadas em diferentes posições no tempo e escala (SIFUZZAMAN; ISLAM; ALI, 2009). Assim como a TF, a TW também usufrui de uma função fixa — chamada de *Wavelet* mãe (algumas delas podem ser visualizadas na Figura 7) — que é utilizada na geração de funções-base localizadas no domínio tempo-frequência a partir da sua translação e dilatação (LEE; YAMAMOTO, 1994). Ou seja, a TW funciona de uma maneira semelhante a TFCT, porém a variação da escala (compressão ou dilatação da *Wavelet* mãe) cria janelas de tamanhos diferentes que englobam intervalos de frequência distintos (POLIKAR *et al.*, 1996). Na Figura 8 é possível visualizar o resultado da TW no sinal não-estacionário utilizado na Figura 5.

Figura 7 – Exemplos de diferentes famílias de *Wavelet*.

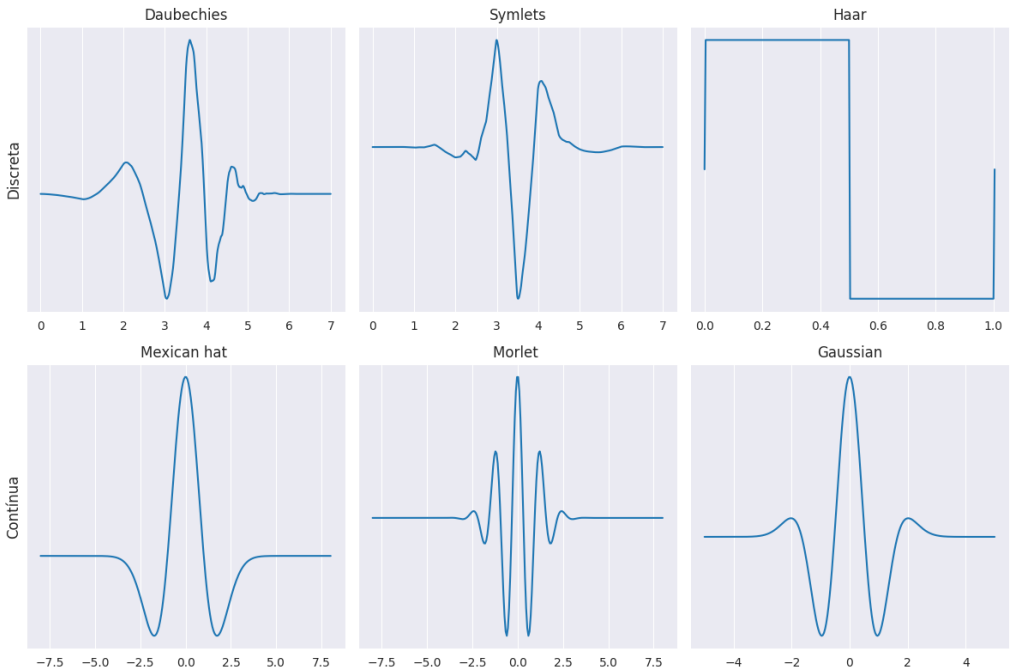

Fonte: Elaboração própria (2023).

Figura 8 – Exemplo do resultado da TW.

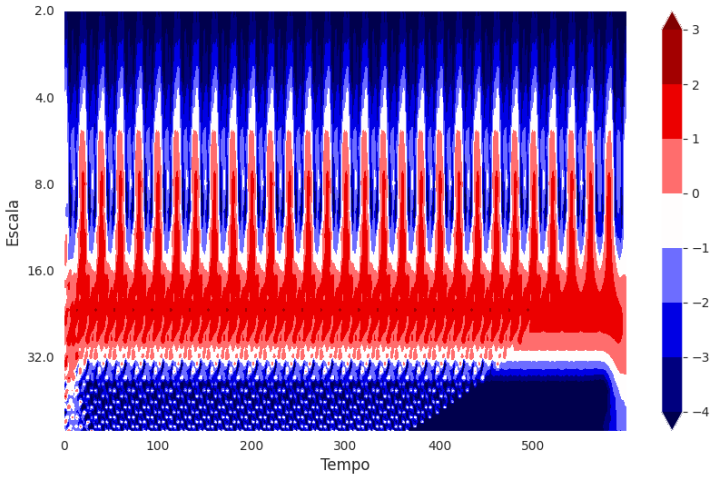

Fonte: Elaboração própria (2023).

De uma maneira geral, a TW pode ser categorizada em dois tipos: Transformada Contínua *Wavelet* (TCW) ou Transformada Discreta *Wavelet* (TDW). A TCW utiliza apenas uma função especial para transformar um sinal contínuo no domínio do tempo para o domínio tempo-frequência, enquanto a TDW utiliza um par de filtros de frequência de baixa e alta passagem para que o sinal contínuo seja separado em diferentes escalas e intervalos de frequência (gerando uma árvore de decomposição) no domínio tempo-frequência (GUIDO *et al.*, 2020). Não restringindo a apenas essas duas classificações, a TW também pode ser categorizada como uma Transformada de Pacotes *Wavelet* (TPW), que além da decomposição das regiões de baixa frequência realizada pela TDW, também realiza a decomposição das regiões de alta frequência (GAO *et al.*, 2011). Na Figura 9 é possível verificar a diferença entre TDW e TPW — BP e AP significam "baixa passagem"e "alta passagem", respectivamente.

Figura 9 – Comparação entre a TDW e TPW.

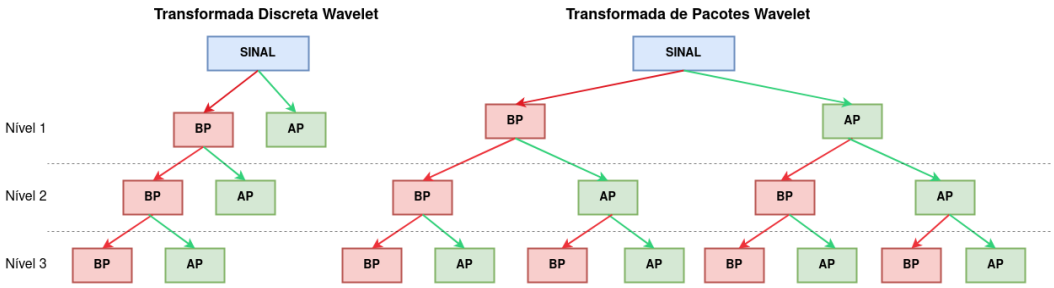

Fonte: Elaboração própria (2023).

2.5 Métricas de Avaliação

A etapa de avaliação do modelo desenvolvido é uma das mais importantes durante o processo de desenvolvimento, pois é nela onde é feita a análise do seu desempenho em dados que não foram vistos durante o treinamento do modelo. Existem diversos tipos de métricas que podem ser usadas e que variam segundo o tipo de aprendizado do problema abordado (se é supervisionado ou não-supervisionado, por exemplo). Posto isso, as métricas usadas no trabalho foram: *F1-Score*, que é bastante utilizada em conjuntos de dados desbalanceados e é a métrica utilizada no evento da PROPOR; Acurácia, é a métrica mais simples e mostra quanto o modelo acertou; ROC-AUC, mostra quão bem o modelo consegue distinguir entre as classes.

2.5.1 *F1-Score*

Essa métrica é composta por outras duas métricas: Precisão, calculada por intermédio dos valores de Verdadeiro Positivo (VP) e Falso Negativo (FN), como demonstrado na equação 2.1; Revocação, calculada utilizando os valores de VP e Falso Negativo (FN), como demonstrado na Equação 2.2. A fórmula da métrica *F1-Score* está representada na Equação 2.3. A pontuação dessa métrica vai de zero a um e quanto mais próximo de um, melhor é o desempenho do modelo.

$$Precisão = \frac{VP}{VP + FP} \tag{2.1}$$

$$Revocação = \frac{VP}{VP + FN} \tag{2.2}$$

$$F1 - Score = \frac{2 * (Revocação * Precisão)}{Revocação + Precisão} \tag{2.3}$$

2.5.2 Acurácia

A acurácia também utiliza os mesmos conceitos que foram abordados na métrica anterior, porém com a adição do Verdadeiro Negativo (VN), e a sua fórmula pode ser vista na Equação 2.4. A pontuação dessa métrica vai de zero a um e quanto mais próximo de um, melhor é o desempenho do modelo. Apesar de ser bastante utilizada, a sua utilização não é indicada para conjuntos de dados desbalanceados, pois pode dar a falsa impressão de que o modelo possui uma boa performance, sendo que na realidade o modelo pode ter um bom desempenho apenas nas classes majoritárias.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} \tag{2.4}$$

2.5.3 ROC-AUC

A métrica curva ROC é composta por duas métricas: Taxa de Verdadeiro Positivo (TVP), calculada por intermédio dos valores de VP e FN, como demonstrado na equação 2.5; Taxa de Falso Positivo (TFP), calculada utilizando os valores de FP e VN, como demonstrado na Equação 2.6.

$$TVP = \frac{VP}{VP + FN} \tag{2.5}$$

$$TFP = \frac{FP}{VN + FP} \tag{2.6}$$

Por fim, ROC-AUC é dada pela soma da área que está abaixo da curva ROC, como demonstrado na Figura 10. A pontuação dessa métrica vai de zero a um e quanto mais próximo de um, melhor é o desempenho do modelo.

Figura 10 – Exemplo de ROC-AUC.

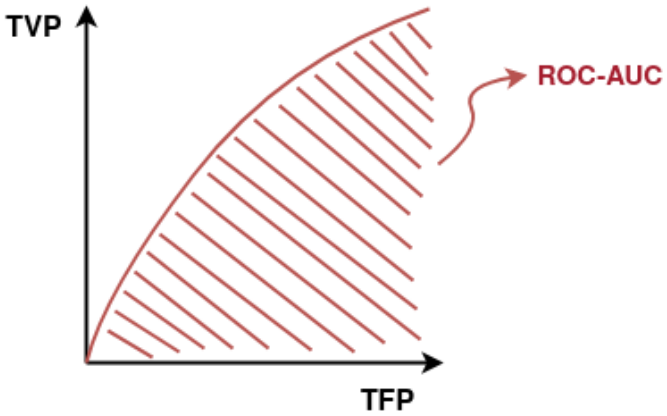

Fonte: Elaboração própria (2023).

3 TRABALHOS RELACIONADOS

Existem diversos trabalhos na literatura que abordam o tema de reconhecimento de emoção da fala e que se diferenciam das mais diversas maneiras, seja pelo conjunto de dados utilizado, a tratativa realizada nesse conjunto, pelo modelo de inteligência artificial utilizado ou quais atributos extraídos dos áudios são utilizados no treinamento desse modelo. Devido a enorme quantidade de trabalhos existentes, houve a necessidade de se realizar um mapeamento sistemático na literatura visando encontrar os que estão mais relacionados com o tema abordado no trabalho.

O mapeamento sistemático é um estudo utilizado quando se deseja obter uma visão ampla em relação a uma determinada área de pesquisa, sendo muito utilizado quando o tópico de pesquisa é muito recente ou não são encontradas muitas evidências na literatura (KEELE *et al.*, 2007). Esse estudo é composto de diferentes etapas que variam entre os trabalhos da literatura. O mapeamento realizado neste trabalho foi feito com o auxílio do Parsifal[1] — uma ferramenta *on-line* que ajuda no planejamento, organização e desenvolvimento de revisões sistemáticas e mapeamento sistemáticos — e as etapas foram baseadas nas que foram utilizadas em (PETERSEN *et al.*, 2008), sendo elas: definição das perguntas da pesquisa, condução de uma busca para encontrar trabalhos relevantes, triagem dos trabalhos e, por fim, apresentação do resultado obtido no mapeamento.

O principal objetivo da aplicação do estudo sistemático é identificar e explorar trabalhos na literatura que utilizam a TW com técnicas de aprendizado profundo ou de máquina na tarefa de reconhecimento de emoção da fala. Posto isso, foram elaboradas as seguintes perguntas:

- "Qual é o algoritmo de aprendizado profundo/aprendizado de máquina utilizado?"
- "Qual é o tipo de TW utilizada (TDW/TCW/TPW)?"
- "Qual é a família da *Wavelet* utilizada?"

Para a etapa de busca dos trabalhos relevantes foram utilizadas a *ACM Digital Library*, *El Compendex (Engineering Village)*, *IEEE Digital Library*, *Scopus* e a *ISI Web of Science* como bibliotecas digitais — por serem bastante conhecidas nas área da computação — e os critérios usados para excluir ou incluir os trabalhos estão definidos na Tabela 1. Todas as buscas foram realizadas utilizando a *string ("speech emotion recognition"OR "ser"OR "speech emotion classification"OR "speech emotion detection") AND ("deep learning"OR "CNN"OR "DNN"OR "LSTM"OR "MLP"OR "deep network"OR "machine learning"OR*

[1] https://parsif.al/

"neural network") AND ("Wavelet"OR "CWT"OR "DWT"OR "Packet") e levando em consideração apenas o título, as palavras-chave e a seção *abstract* do trabalho (exceto para a biblioteca *IEEE Digital Library*, não sendo utilizada a busca avançada). Ademais, só foram considerados os trabalhos da área da computação que foram publicados a partir de 2018. Os resultados iniciais das buscas, assim como as datas em que foram executadas, estão demonstrados na Tabela 2.

Tabela 1 – Critérios de inclusão e exclusão dos trabalhos.

Critério de inclusão	**Critério de exclusão**
Estudos que utilizam TW, aprendizado profundo/aprendizado de máquina na tarefa de reconhecimento de emoção da fala	Estudos duplicados
	Estudos em qualquer idioma que não seja inglês
	Estudos que não são sobre reconhecimento de emoção da fala
	Estudos que não utilizam técnicas de aprendizado profundo/aprendizado de máquina
	Estudos que não usam TW
	Livros, capítulo de livros, slides, pôsteres ou páginas na web
	Sem acesso
	Estudos secundários
	Teses, monografias ou dissertações

Fonte: Elaboração própria (2023).

Tabela 2 – Resultado inicial obtido na busca em cada biblioteca.

Biblioteca	**Data da busca**	**Quantidade de trabalhos encontrados**
El Compendex	01/04/2023 às 18:10	44
ACM Digital Library	02/04/2023 às 18:15	5
IEEE Digital Library	02/04/2023 às 17:35	13
Scopus	01/04/2023 às 14:05	*51
ISI Web of Science	01/04/2023 às 16:10	21
Total	**-**	**134**

*No site da biblioteca foi obtido um total de 53 trabalhos, porém a quantidade reduziu após ser transferido para o Parsifal

Fonte: Elaboração própria (2023).

Com relação à primeira fase de triagem, em um primeiro momento os trabalhos foram avaliados considerando os critérios de exclusão que não estão relacionados diretamente com o seu conteúdo — como a data de publicação, o idioma, se são estudos secundários, dentre outros mencionados na Tabela 1 — e aqueles que não foram descartados foram avaliados considerando o conteúdo do título e das palavras-chave. O resultado dessa fase pode ser visualizado na Figura 11. Nela, é possível observar que somente uma pequena

porção dos trabalhos encontrados passaram pelos critérios de inclusão e, como demonstrado na Figura 12, o principal critério pelo descarte dos trabalhos foi o de estudos duplicados.

Figura 11 – Resultado da primeira triagem realizada nos trabalhos.

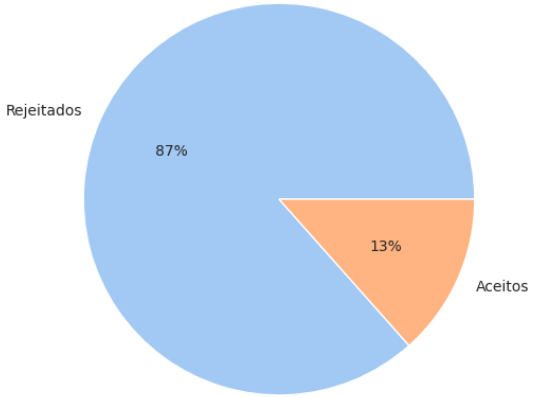

Fonte: Elaboração própria (2023).

Figura 12 – Quantidade de trabalhos rejeitados por critério de inclusão.

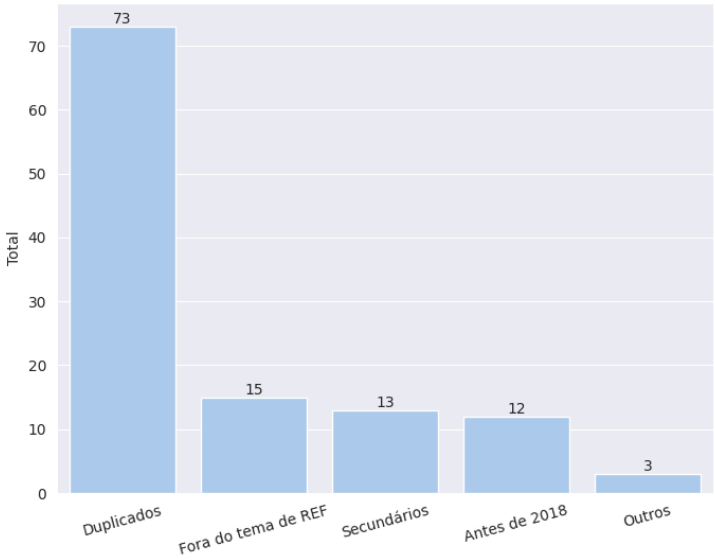

Fonte: Elaboração própria (2023).

Com relação à segunda fase da triagem, foi considerado apenas o conteúdo presente na seção de *abstract* dos trabalhos. Além das condições de exclusão apresentadas na Tabela 1, também foram realizados os seguintes levantamentos: se a etapa de extração da TW é

uma das principais no processamento dos dados (não é utilizada apenas como um filtro, por exemplo) e se o problema abordado não são múltiplas tarefas (ataca mais de uma tarefa ao mesmo tempo). Ao final do processo de seleção, apenas 13 dos 18 trabalhos passaram pelos critérios. Dos cinco que foram descartados, um foi pelo critério de abordar múltiplas tarefas, um por não utilizar a TW, um não cita como a TW foi utilizada e os outros dois por não utilizarem a TW como uma das etapas principais do processamento de dados.

Com relação à terceira e última fase da triagem, todos os trabalhos selecionados foram lidos por inteiro e utilizando as mesmas condições de exclusão das etapas anteriores. Ao final dessa etapa, foram considerados somente os trabalhos que respondessem pelo menos 2 das 3 perguntas propostas inicialmente. Dos 13 artigos iniciais, um foi excluído por falta de acesso, um por ser um trabalho duplicado (nesse caso, ele não foi identificado antes por ter um título e um *abstract* diferente da outra cópia e ter sido publicado em outra revista), um por ser capítulo de livro, um não passou pelo critério da quantidade de perguntas respondidas e um não utiliza a TW como uma das etapas principais do processamento de dados. O resultado do mapeamento sistemático e o gráfico de bolhas com os trabalhos selecionados após todas as etapas de triagem podem ser vistos na Tabela 3 e na Figura 13, respectivamente.

Tabela 3 – Resultado do mapeamento sistemático.

Estudo	**Modelo(s) utilizado(s)**	**Tipo da transformada *Wavelet***	**Família da *Wavelet***
(FENG; YANG, 2018)	LSTM	TPW	Daubechies
(TANMOY *et al.*, 2018)	SVM, NB, KNN	TDW	Daubechies
(KODURU; VALIVETI; BUDATI, 2020)	SVM, Árvore de Decisão, *Linear Discriminant Analysis*	TDW	*Haar
(AGHAJANI; AFRAKOTI, 2020)	*RNC-LSTM*	Escalograma	Morlet
(MENG *et al.*, 2021)	*LSTM* bidirecional com atenção	TPW	Daubechies
(NUGROHO; FUADIYAH, 2022)	Perceptron Múltiplas Camadas	TDW	Daubechies
(SEKKATE *et al.*, 2019)	NB e SVM	TDW	-
(HUANG *et al.*, 2019)	Rede de Crenças Profundas (*Deep Belief Network*, em tradução livre)	TPW	-

*Mencionado no trabalho, porém não é citado de maneira direta a sua utilização.
Fonte: Elaboração própria (2023).

Figura 13 – Quantidade de trabalhos rejeitados por critério de avaliação.

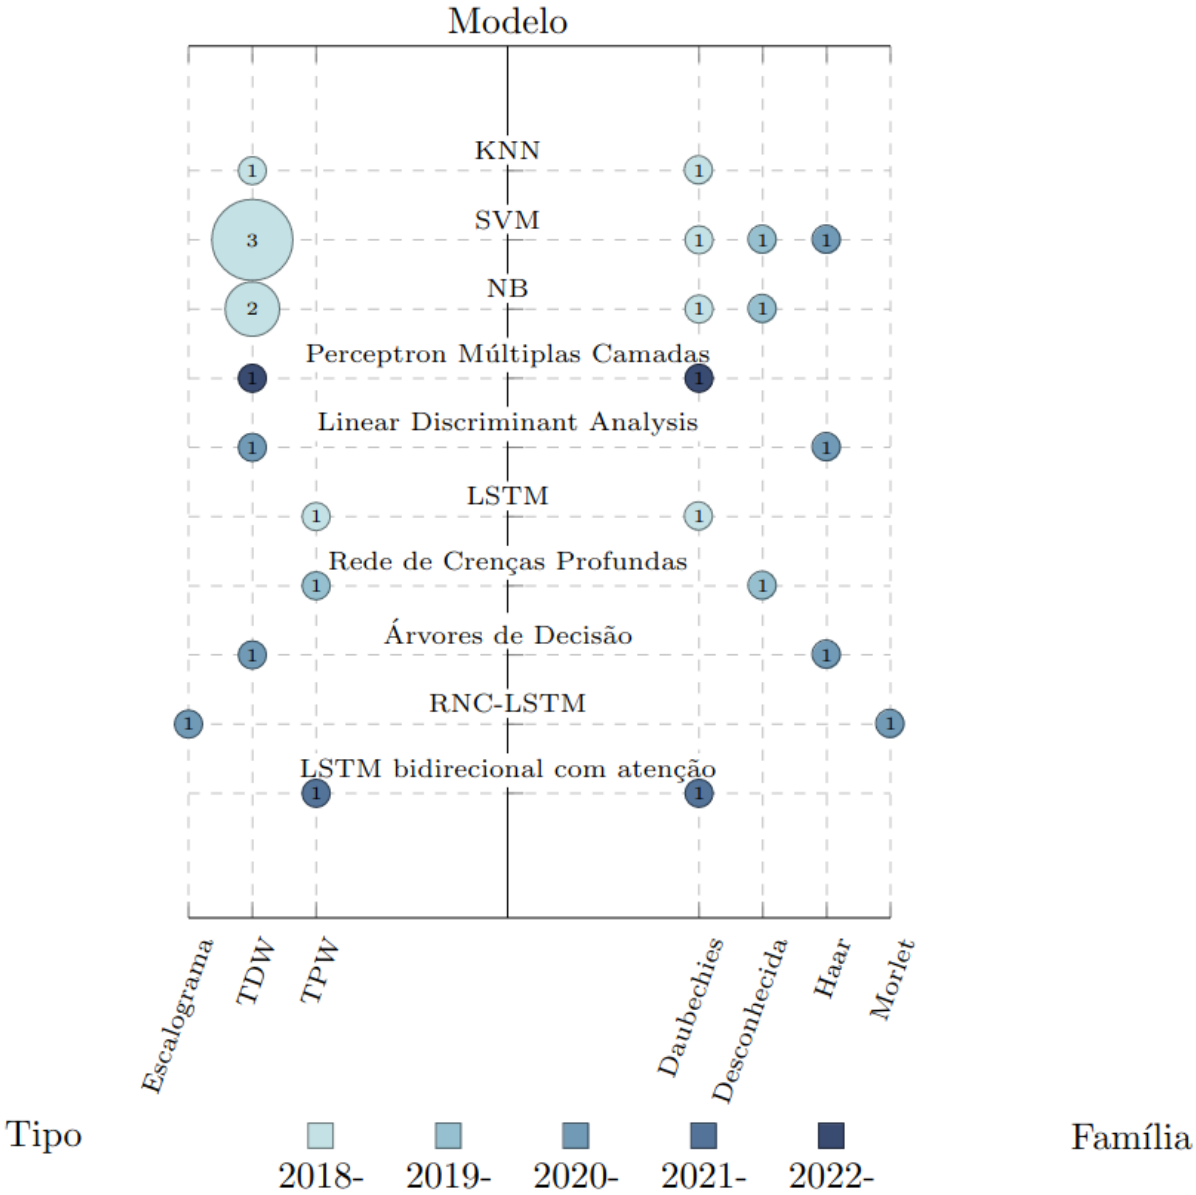

Fonte: Elaboração própria (2023).

4 MATERIAIS E MÉTODOS

Este capítulo procura descrever todas as etapas realizadas durante o desenvolvimento deste trabalho, demonstradas no fluxograma da Figura 14. Ele está organizado da seguinte forma: será discorrido sobre as bases de dados selecionadas na Seção 4.1, o ambiente de execução utilizado na Seção 4.2, as ferramentas utilizadas na preparação do ambiente na Seção 4.3, as etapas realizadas no processamento dos dados na Seção 4.4, os modelos de classificação desenvolvidos na Seção 4.5 e, por fim, as métrica utilizadas para avaliar os modelos desenvolvidos na Seção 4.6.

Figura 14 – Fluxograma das etapas de desenvolvimento do trabalho.

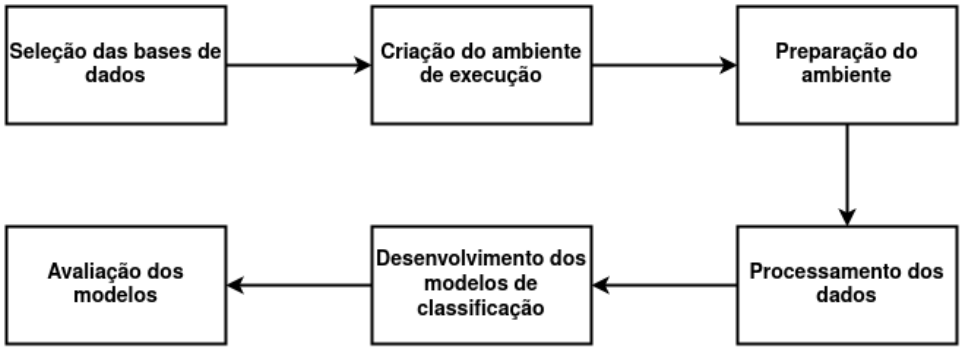

Fonte: Elaboração própria (2023).

4.1 Bases de Dados

Existem diversas bases diferentes usadas na literatura, como, por exemplo, as bases de fala espontânea (*RECOLA Speech Database* e *SAMAINE Database*), fala atuada (EMODB e SAVEE) e de fala eliciada (*Interactive Emotional Motion Capture e* Oriya Emotion Speech Dataset) (WANI *et al.*, 2021). Para este trabalho, serão utilizadas as bases da CORAA, por ser uma base de fala espontânea e a única encontrada no idioma português do Brasil, EMODB, SAVEE e RAVDESS — por serem as bases de dados mais utilizadas nos estudos encontrados no mapeamento sistemático (debatido no Capítulo 3).

4.1.1 CORAA

O conjunto de dados da CORAA (MARCACINI; JUNIOR; CASANOVA, 2022) foi proposto no evento da PROPOR e também está disponível no *GitHub*[1]. Este conjunto de dados é composto de falas espontâneas gravadas por homens e mulheres no idioma português do Brasil, com taxa de aquisição de 16.000Hz e no formato mono — só possuem um canal. Os dados foram rotulados em três classes diferentes: neutro, homem não-neutro

[1] https://github.com/rmarcacini/ser-coraa-pt-br/

e mulher não-neutro. Ele é dividido em dois: para treinamento, contendo aproximadamente 40 minutos de duração; para teste, com cerca de 21 minutos de duração. A distribuição das partes do conjunto pode ser vista na Figura 15. Nela, é possível observar o desbalanceamento entre as classes, visto que ela é composta por muito mais dados da classe neutro do que nas demais classes em ambas partições do conjunto.

Figura 15 – Distribuição do conjunto de dados CORAA.

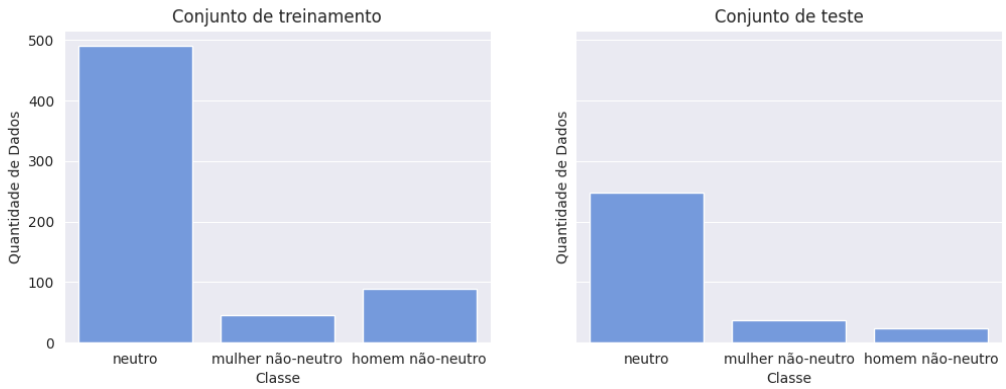

Fonte: Elaboração própria (2023).

(SALVES *et al.*, 2022) realizaram uma análise dos dados de treinamento levando em consideração quatro observações: presença de ruído, sobreposição de vozes, diferentes gêneros no mesmo áudio e vozes em sequência (presença de mais de uma voz primária no mesmo áudio). Como resultado, demonstrado na Figura 16, foi encontrada uma grandeza de áudios com ocorrência de sobreposição de vozes e com diferentes gêneros no mesmo áudio — podendo dificultar e afetar o processo de aprendizagem do modelo de classificação.

Figura 16 – Análise qualitativa do conjunto de dados da CORAA.

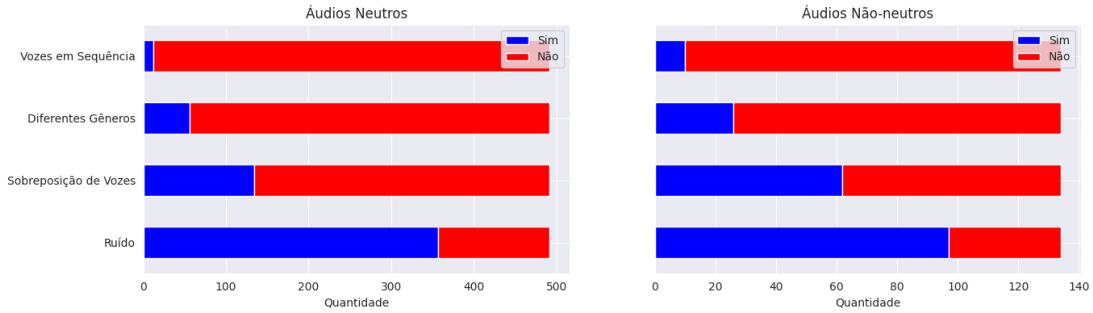

Fonte: Adaptado de (SALVES *et al.*, 2022) (2023).

4.1.2 EMODB

O conjunto de dados EMODB (BURKHARDT *et al.*, 2005), disponível no seu site oficial[2], é composto por falas atuadas gravadas por dez atores profissionais de várias

[2] http://www.emodb.bilderbar.info

idades (5 homens e 5 mulheres) no idioma alemão, com taxa de aquisição de 16.000Hz e no formato mono. Para as gravações foram disponibilizadas algumas frases, curtas e longas, que foram lidas pelos atores com entonação de acordo com uma determinada emoção (felicidade, medo, neutro, nojo, tédio, tristeza ou raiva). O conjunto tem um total de 25 minutos de duração e sua distribuição pode ser vista na Figura 17 e, assim como o CORAA, também não é balanceada.

Figura 17 – Distribuição do conjunto de dados EMODB.

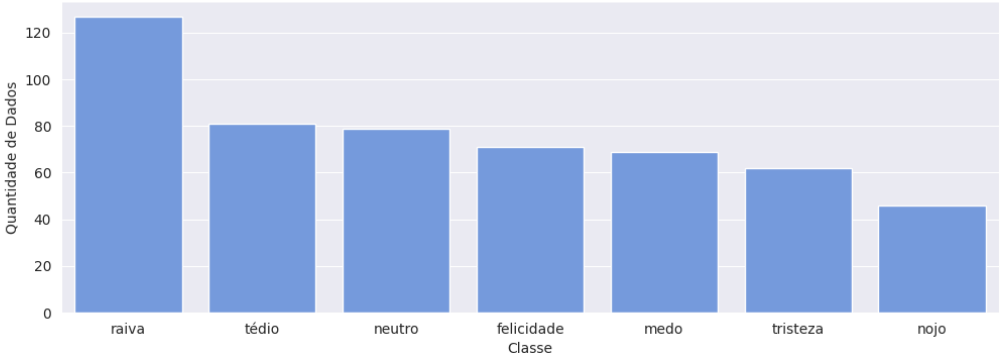

Fonte: Elaboração própria (2023).

4.1.3 RAVDESS

O conjunto de dados RAVDESS (LIVINGSTONE; RUSSO, 2018), disponível no site Zenodo[3], é composto por áudios e vídeos de falas atuadas por 24 atores profissionais (12 homens e 12 mulheres) no idioma inglês da América do Norte, com taxa de aquisição de 48.000Hz e no formato estéreo e mono. É importante ressaltar que neste trabalho só foram utilizados os dados disponibilizados no formato de áudio e de fala. Para as gravações foram disponibilizadas algumas frases lidas pelos atores com entonação de acordo com uma determinada emoção (neutro, calmo, felicidade, tristeza, raiva, medo, nojo e surpresa) e com diferentes intensidades (normal e grande) — exceto para a classe neutra, que só possui a intensidade normal. O conjunto tem cerca de 90 minutos de duração e sua distribuição pode ser vista na Figura 18. Nela, é possível observar que, diferente das bases anteriores, ela é balanceada.

[3] https://zenodo.org/record/1188976

Figura 18 – Distribuição do conjunto de dados RAVDESS.

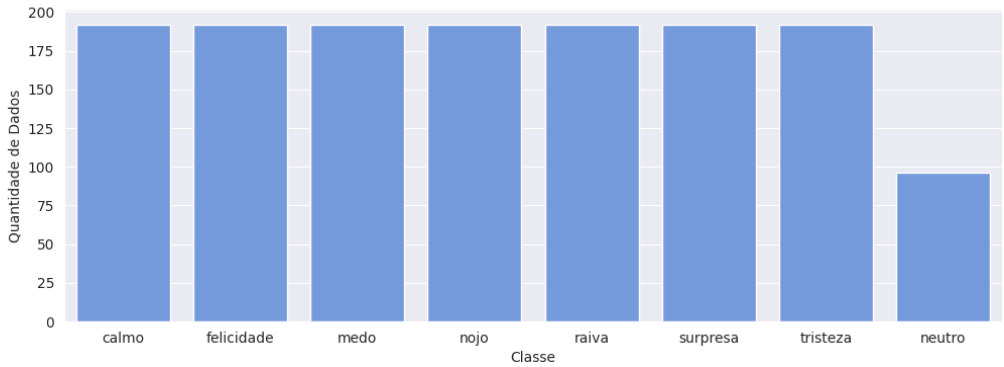

Fonte: Elaboração própria (2023).

4.1.4 SAVEE

O conjunto de dados SAVEE (VLASENKO *et al.*, 2007), desenvolvido pela Universidade de Surrey e disponível no seu site oficial[4], é composto por áudios e vídeos de falas atuadas por 4 atores profissionais (todos homens) no idioma inglês britânico, com taxa de aquisição de 44.100Hz e no formato mono. É importante ressaltar que neste trabalho só foram utilizados os dados disponibilizados no formato de áudio. Para as gravações foram disponibilizadas algumas frases lidas pelos atores com entonação de acordo com uma determinada emoção (neutro, raiva, medo, felicidade, tristeza e surpresa). O conjunto tem cerca de 31 minutos de duração e sua distribuição pode ser vista na Figura 19. Nela, é possível observar que as classes das emoções são balanceadas, porém, existe uma maior quantidade de dados da classe neutra.

Figura 19 – Distribuição do conjunto de dados SAVEE.

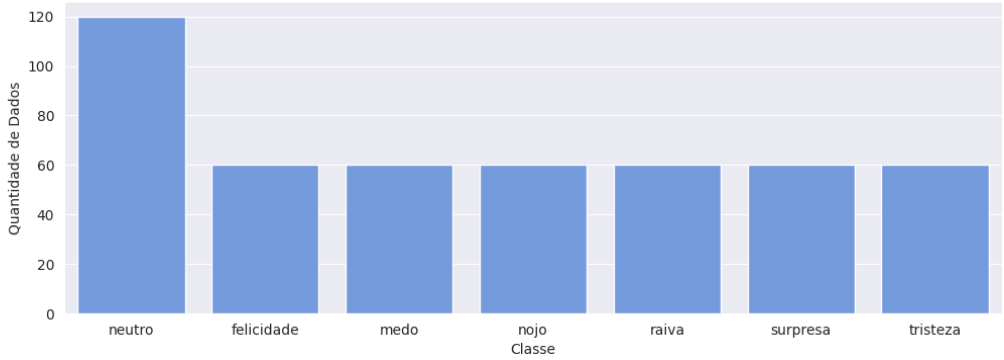

Fonte: Elaboração própria (2023).

[4] http://kahlan.eps.surrey.ac.uk/savee/

4.2 Ambiente de Execução

Todas as etapas do trabalho foram executadas utilizando o *Google Colab Pro*[5], uma plataforma que oferece acesso gratuito a recursos computacionais — como GPUs e TPUs — e que é acessada de maneira remota pelo navegador, por meio de um arquivo hospedado do *Jupyter Notebook* (RESEARCH, 2018). A versão *Pro* é paga e oferece uma maior quantidade de memória RAM, recursos computacionais mais potentes e com mais tempo de uso. Para esse trabalho foi utilizado um ambiente pré-definido pelo *Google Colab* com cerca de 170 GB de armazenamento e uma *GPU* T4 com 15 GB de memória integrada.

4.3 Ferramentas Utilizadas

Os códigos desenvolvidos durante o desenvolvimento do trabalho foram feitos utilizando a versão 3.8.10 da linguagem de programação *Python* 3 e disponibilizados no *GitHub*[6]. Para o desenvolvimento dos modelos de aprendizado profundo foi utilizada a biblioteca *PyTorch* na versão 1.13.1, pois ela oferece suporte a utilização de GPUs, é fácil de realizar *debugging*, consistente com outras bibliotecas populares da computação e estilo de programação "pythonico"(PASZKE *et al.*, 2019). Para a utilização dos códigos na GPU foi utilizada a versão 11.7 do CUDA.

Para a manipulação dos dados, extração do espectrograma na escala mel e o desenvolvimento das etapas de *data augmentation* foram utilizadas as versões 0.13.1, 1.23.5 e 1.5.2 das bibliotecas *TorchAudio*, *numpy* e *pandas*, respectivamente. Para a extração da TW foi utilizada a biblioteca *PyWavelets* na versão 1.4.1. E, por fim, para a avaliação do desempenho dos modelos desenvolvidos foi utilizada a versão 1.2.0 da biblioteca *scikit-learn*.

4.4 Processamento dos Dados

Para a etapa de pré-processamento dos dados, devido à limitação do uso da GPU, foi necessário realizar a reamostragem dos áudios para a taxa de aquisição de 8.000Hz. Em seguida, os vetores de dados dos áudios foram preenchidos com o valor zero no final até ficarem com o mesmo tamanho do vetor do maior áudio da base. Além disso, todos os áudios foram convertidos para terem somente um canal e seus valores foram normalizados.

Para a etapa de extração de característica dos áudios foi realizada a extração do espectrograma na escala mel — por ser uma técnica bastante usada nessa tarefa em questão, ser utilizada originalmente no modelo de aprendizado profundo que foi baseado para desenvolver os modelos deste trabalho e ser a escolha dos autores (GAUY; FINGER, 2022) e (ISSA; DEMIRCI; YAZICI, 2020).

[5] https://colab.google/
[6] https://github.com/rafaelgreca/ser-wavelet

Como os conjuntos de dados utilizados nesse trabalho são pequenos e desbalanceados, foi de suma importância o emprego de técnicas de *data augmentation* para aumentar a quantidade de dados disponíveis no conjunto de treinamento. A técnica utilizada é chamada *SpecAugment* e consiste em mascarar blocos de sinais de frequência e de etapas do tempo (PARK *et al.*, 2019). Um exemplo da aplicação dessa técnica pode ser visto na Figura 20, selecionado aleatoriamente uma faixa — de tamanho aleatório — da frequência e tempo e mascarado usando a técnica descrita.

Figura 20 – Exemplo de utilização da técnica *SpecAugment*.

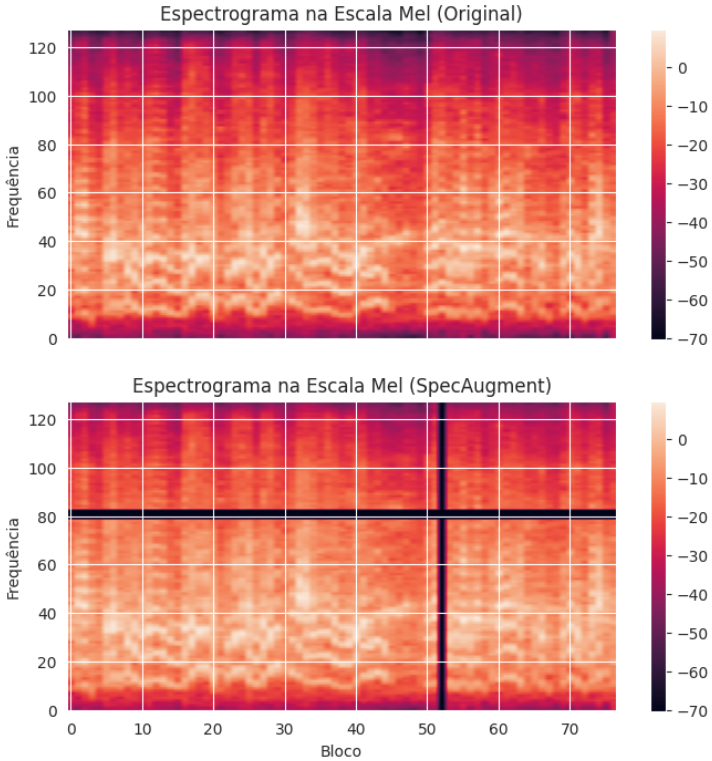

Fonte: Elaboração própria (2023).

Por fim, para a etapa de extração da TW foi utilizado a TDW e a família Daubechies, visto que essas foram as características mais usadas entre os trabalhos selecionados no mapeamento sistemático descrito no Capítulo 3.

4.5 Modelos de Classificação

Foram utilizadas a Rede Neural de Áudio Pré-treinada (RNAP) para reconhecimento de padrões de áudio em larga escala das variações RNC 6 e RNC 10 desenvolvida por (KONG *et al.*, 2020), também utilizadas por (GAUY; FINGER, 2022), e uma adaptação da RNC-LSTM desenvolvida por (AGHAJANI; AFRAKOTI, 2020) — o modelo original foi testado e não obteve um bom resultado, sendo assim foi utilizado somente a RNC. Devido à limitação do uso da GPU, foi utilizado o valor 16 para o tamanho do *batch*, 100

épocas para os modelos RNAP e 50 para a RNC. Ademais, foi utilizada o valor 0.001 como taxa de aprendizado.

4.5.1 RNAP RNC 6

Como pode ser visto na Figura 21, o modelo RNAP RNC 6 é composto por quatro blocos convolucionais (cada um é constituído de uma camada convolucional, seguido de uma camada de normalização de *batch* e a função não-linear *ReLU*), quatro blocos de *pooling* da métrica de média e duas camadas densas. Todas as camadas convolucionais dos blocos possuem *kernel* de tamanho 5x5 e um *kernel* de tamanho 2x2 nas camadas de *pooling*. O primeiro bloco convolucional possui 64 canais de saída, o segundo possui 128 canais de saída, o terceiro possui 256 canais de saída e o quarto possui 512 canais de saída. Depois é seguido de uma camada densa com 512 unidades com a função não-linear *ReLU* e, por fim, uma camada densa com a quantidade de saída igual ao número de classes e com a função de ativação *Softmax*.

Figura 21 – Arquitetura do modelo RNAP RNC 6.

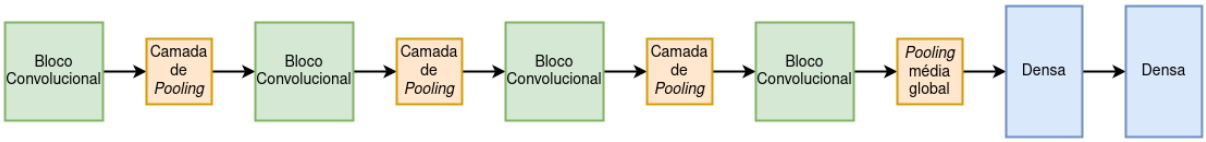

Fonte: Elaboração própria (2023).

4.5.2 RNAP RNC 10

Como pode ser visto na Figura 22, o modelo RNAP RNC 10 é composto por quatro blocos convolucionais (cada um é constituído de uma camada convolucional seguida de uma camada de normalização de *batch*, outra camada convolucional seguida de uma camada de normalização de *batch*, a função não-linear *ReLU* e uma camada de *pooling* da métrica de média) e duas camadas densas. Todas as camadas convolucionais dos blocos possuem *kernel* de tamanho 3x3 e um *kernel* de tamanho 2x2 nas camadas de *pooling*. No primeiro bloco convolucional ambas camadas convolucionais possuem 64 canais de saída, no segundo ambas possuem 128 canais de saída, no terceiro ambas possuem 256 canais de saída e no quarto ambas possuem 512 canais de saída. Depois é seguido de uma camada densa com 512 unidades com a função não-linear *ReLU* e, por fim, uma camada densa com a quantidade de saída igual ao número de classes e com a função de ativação *Softmax*.

Figura 22 – Arquitetura do modelo RNAP RNC 10.

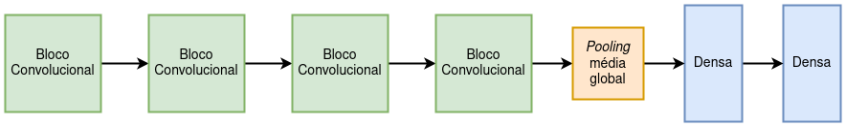

Fonte: Elaboração própria (2023).

4.5.3 RNC

Como pode ser visto na Figura 23, o modelo é composto por cinco blocos convolucionais (cada um é constituído de uma camada convolucional seguida de uma camada de normalização de *batch* e a função não-linear *ReLU*), duas camadas de *pooling* da métrica máxima e uma camada densa. Como não foi mencionado pelos autores (AGHAJANI; AFRAKOTI, 2020), todos os valores dos parâmetros das camadas foram escolhidos arbitrariamente. Sendo assim, foram escolhidos um *kernel* de tamanho 3x3 para todas as camadas convolucionais dos blocos e um *kernel* de tamanho 2x2 para as camadas de *pooling*. O primeiro bloco convolucional possui 64 canais de saída, o segundo possui 128, o terceiro possui 256, o quarto possui 512 e o quinto possui 1024. Por fim, é utilizada uma camada densa com a quantidade de saída igual ao número de classes e com a função de ativação *Softmax*.

Figura 23 – Arquitetura do modelo RNC.

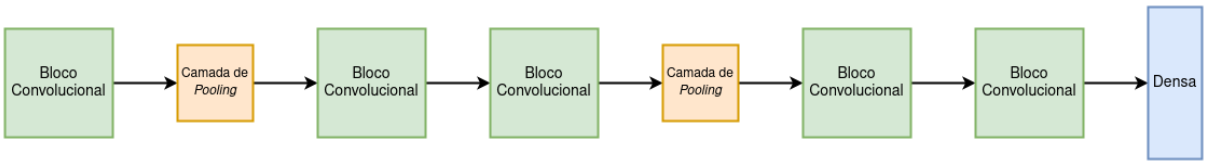

Fonte: Elaboração própria (2023).

4.6 Avaliação do Modelo

Para a base de dados da CORAA, a avaliação do modelo desenvolvido foi feita utilizando a métrica *F1-Score macro* — mesma métrica usada para avaliar os modelos submetidos durante o evento da PROPOR[7], além de ser bastante utilizada na tarefa de reconhecimento de emoção da fala por fazer a proporção das métricas de revocação e precisão (citado no Capítulo 2). Já para as bases EMODB, RAVDESS e SAVEE, foi utilizada a acurácia sem balanceamento — por ser a métrica utilizada nos trabalhos encontrados no mapeamento sistemático (trazido no Capítulo 3). Além dessas métricas, para obter uma melhor percepção do desempenho dos modelos, também foram utilizadas a matriz de confusão e a ROC-AUC.

[7] https://sites.google.com/view/ser2022/home

5 EXPERIMENTOS E RESULTADOS

Este capítulo visa detalhar os experimentos realizados e os resultados obtidos. A etapa de experimentações foi realizada considerando apenas o conjunto de dados da CORAA, e a melhor configuração encontrada foi utilizada para treinar o melhor modelo para as outras bases de dados.

A base de dados de treinamento foi dividida em cinco utilizando a técnica *kfold* e mantendo a mesma distribuição das classes do conjunto na totalidade, sendo que 80% dos dados foram utilizados para treinar o modelo e os outros 20% para a validar o modelo durante a etapa de treinamento. No caso da base da CORAA, para teste foi utilizado o conjunto oficial disponibilizado pelo evento do PROPOR e que foi descrito no Capítulo 4. Ademais, como o conjunto da CORAA não possui identificação dos falantes nos arquivos, a divisão da base foi feita aleatoriamente (não usa falantes diferentes no treinamento e na validação) — tornando a solução desenvolvida dependente do falante. Para que a comparação entre os desempenhos dos modelos fosse mais fiel, garantindo que os modelos utilizem os mesmos conjuntos de treinamento e validação, foi utilizada a semente 2109 na divisão da base de dados.

Inicialmente, com o intuito de melhorar a qualidade dos dados, foram realizados experimentos com algoritmos de detecção de atividade de voz — cujo objetivo é detectar o começo e um fim da fala, eliminando silêncio e trechos sem fala presentes no áudio. Para isso, foram utilizados o algoritmo do WebRTC e o modelo disponibilizado pela biblioteca *PyTorch*, e para validar o resultado do experimento foi realizada uma análise qualitativa usando uma pequena porção da base de dados. Como é possível observar na Figura 24, em alguns áudios foi observado um bom resultado, mantendo somente a fala e removendo silêncio e barulhos, porém o mesmo não foi observado na grande maioria dos áudios e acarretando perda de conteúdo que possa ser valioso para a tarefa em questão. Os hiper-parâmetros dos modelos foram alterados a fim de averiguar uma possível melhora dos resultados, contudo o mesmo comportamento descrito anteriormente se manteve. Por se tratar de uma base de dados com falas espontâneas — e com ruídos de fundo — esse cenário era esperado e, portanto, a ideia de utilizar um algoritmo para detectar a atividade de voz foi descartada.

Figura 24 – Exemplos do experimento qualitativo com algoritmos de detecção de atividade de voz.

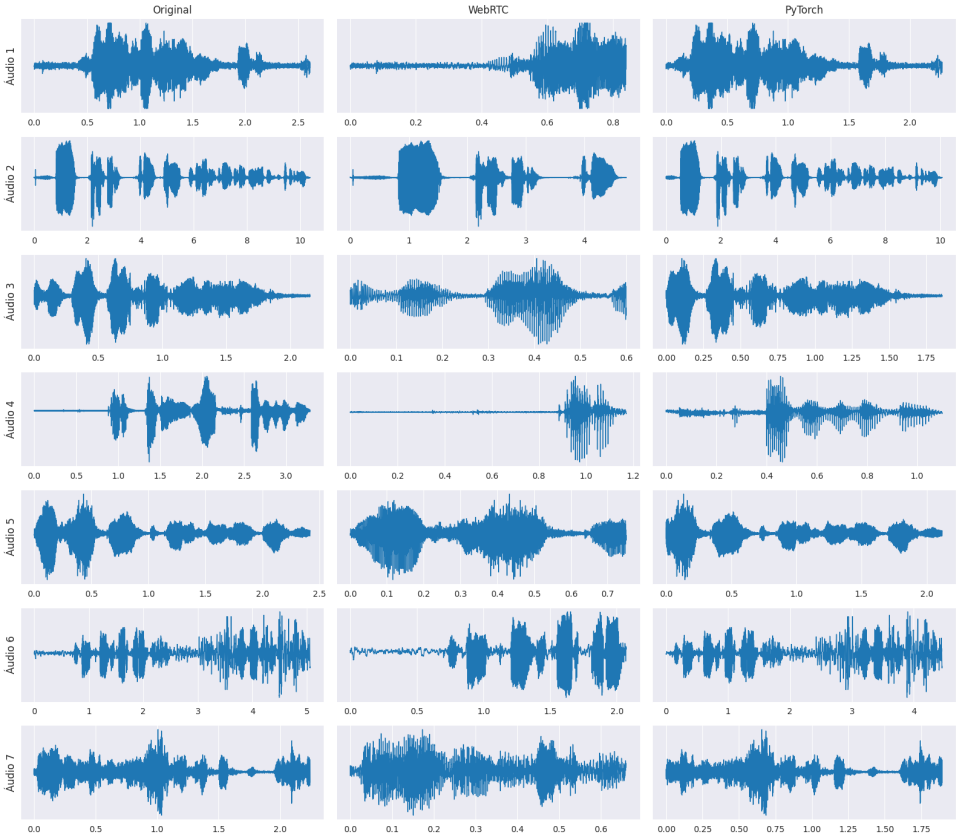

Fonte: Elaboração própria (2023).

Primeiramente, para todos os modelos foram realizadas variações nos parâmetros da etapa de extração do espectrograma na escala mel, nos parâmetros da etapa de extração da TW e na ordem que ocorre a extração das características. Como é possível aplicar a TW tanto em imagem quanto em áudio bruto, foram elaboradas as seguintes estratégias: ordem 1, primeiro o espectrograma na escala mel é extraído do áudio bruto, em seguida é realizada a extração da TW utilizando o espectrograma e, por fim, seus coeficientes resultantes são unidos, formando uma espécie de imagem com um canal; ordem 2, primeiro é aplicada a TW no áudio bruto, em seguida é extraído o espectrograma na escala mel de cada coeficiente resultante da extração da TW e, por fim, seus espectrogramas são preenchidos para terem o mesmo tamanho e se tornarem uma imagem com múltiplos canais. Ambos processos de extração podem ser vistos na Figura 25. Todas as opções de valores utilizados nos experimentos estão apresentados na Tabela 4.

Figura 25 – Exemplo das diferentes ordens de execução de extração de características.

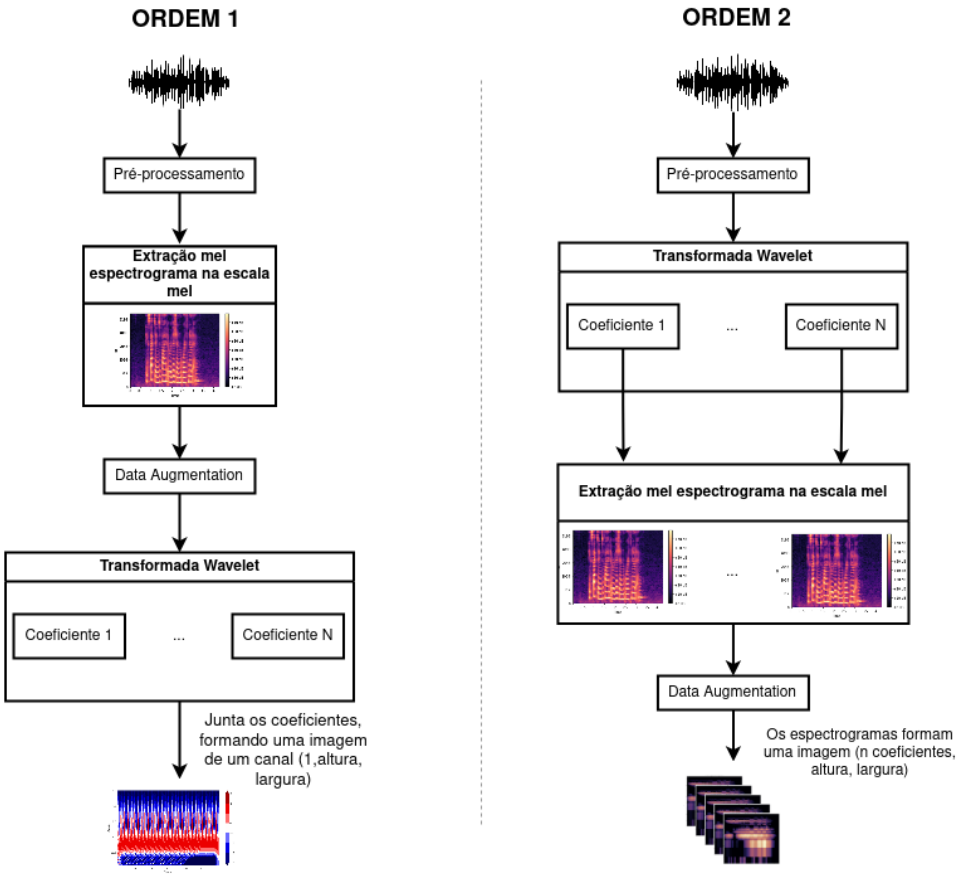

Fonte: Elaboração própria (2023).

Tabela 4 – Opções das variações utilizadas nos experimentos.

Tipo da variação	**Valores**
Ordem	1 e 2
Espectrograma na escala mel	Opção 1: 128 *mels*, 400 TF e 200 deslocamento
	Opção 2: 128 *mels*, 1024 TF e 320 deslocamento
TW	Opção 1: *Wavelet* db6 e nível 3
	Opção 2: *Wavelet* db8 e nível 3
	Opção 3: *Wavelet* db4 e nível 3

Fonte: Elaboração própria (2023).

O primeiro modelo testado foi o RNAP CNN6 e os resultados podem ser vistos na Tabela 5, cujos melhores — com base na performance obtida nos dados de validação — estão em negrito. Nela, é possível perceber que no geral ambas as ordens tiveram resultados parecidos no conjunto de validação, com a melhor combinação da ordem 1 e da ordem 2 obtendo um *F1-Score* médio de 0.505 e 0.5218, respectivamente, nos dados de validação e

0.4519 e 0.4517 nos dados de teste. Apesar dos resultados semelhantes, no geral os modelos da ordem 1 obtiveram uma melhor generalização no conjunto de teste.

Tabela 5 – Resultado dos experimentos com o modelo RNAP CNN6.

Ordem	**TW**	**Espectrograma na escala mel**	***F1-Score* Validação**	***F1-Score* Teste**
Ordem 1	**1**	**1**	**0.505 ± 0.0369**	**0.4519 ± 0.0193**
	2	2	0.4758 ± 0.0385	0.4464 ± 0.0373
	3	1	0.505 ± 0.0348	0.4442 ± 0.0215
	1	2	0.5046 ± 0.0369	0.4399 ± 0.0426
	2	1	0.4651 ± 0.0268	0.442 ± 0.027
	3	2	0.5022 ± 0.0453	0.4659 ± 0.0244
Ordem 2	**1**	**1**	**0.5218 ± 0.0678**	**0.4517 ± 0.0364**
	2	2	0.4778 ± 0.0352	0.4278 ± 0.0208
	3	1	0.4881 ± 0.0762	0.4043 ± 0.0293
	1	2	0.4978 ± 0.0487	0.4232 ± 0.0127
	2	1	0.505 ± 0.0528	0.4117 ± 0.0574
	3	2	0.4963 ± 0.0425	0.4235 ± 0.0221

Fonte: Elaboração própria (2023).

O segundo modelo testado foi o RNAP CNN10 e os resultados podem ser vistos na Tabela 6, cujos melhores estão em negrito. Nela, além de observar uma melhoria no desempenho, é possível perceber que a ordem 1 teve resultados superiores em todas as combinações, tanto nos dados de validação quanto nos de teste, em relação à ordem 2. E, assim como observado no cenário anterior, a ordem 1 possui uma melhor generalização nos dados de teste. Ademais, dentre os modelos executados na melhor combinação da ordem 1, o maior *F1-Score* encontrado nos dados de validação e teste foram 0.6669 e 0.5663, respectivamente.

Tabela 6 – Resultado dos experimentos com o modelo RNAP CNN10.

Ordem	**TW**	**Espectrograma na escala mel**	***F1-Score* Validação**	***F1-Score* Teste**
Ordem 1	1	1	0.5322 ± 0.0494	0.4683 ± 0.0439
	2	2	0.5051 ± 0.0387	0.473 ± 0.0657
	3	**1**	**0.5532 ± 0.08**	**0.4931 ± 0.0886**
	1	2	0.5001 ± 0.037	0.4636 ± 0.0492
	2	1	0.5406 ± 0.0316	0.4624 ± 0.0357
	3	2	0.5352 ± 0.0341	0.4712 ± 0.0535
Ordem 2	1	1	0.473 ± 0.0369	0.3939 ± 0.0187
	2	2	0.459 ± 0.0524	0.4405 ± 0.061
	3	**1**	**0.4826 ± 0.0539**	**0.3973 ± 0.0246**
	1	2	0.4815 ± 0.0614	0.3931 ± 0.022
	2	1	0.4605 ± 0.0282	0.427 ± 0.0312
	3	2	0.4722 ± 0.038	0.4068 ± 0.0398

Fonte: Elaboração própria (2023).

O terceiro modelo testado foi a RNC e os resultados podem ser vistos na Tabela 7, cujos melhores estão em negrito. Nela, é possível observar uma piora significativa quando comparado aos resultados anteriores. Além disso, com o cenário um pouco diferente do que foi observado nos testes anteriores: ordem 1 teve um desempenho maior nos dados de validação e generaliza melhor com os dados de teste, porém com uma diferença menor.

Tabela 7 – Resultado dos experimentos com o modelo RNC.

Ordem	**TW**	**Espectrograma na escala mel**	***F1-Score* Validação**	***F1-Score* Teste**
Ordem 1	**1**	**1**	**0.4616 ± 0.0584**	**0.4023 ± 0.0203**
	2	2	0.4503 ± 0.041	0.3897 ± 0.0196
	3	1	0.4315 ± 0.0617	0.3742 ± 0.0369
	1	2	0.4257 ± 0.0416	0.3538 ± 0.0259
	2	1	0.4479 ± 0.0318	0.3689 ± 0.034
	3	2	0.4601 ± 0.0524	0.3789 ± 0.0378
Ordem 2	1	1	0.3975 ± 0.0328	0.3415 ± 0.0117
	2	2	0.3897 ± 0.0587	0.3392 ± 0.0182
	3	1	0.4178 ± 0.0178	0.3688 ± 0.054
	1	**2**	**0.4527 ± 0.034**	**0.3714 ± 0.0388**
	2	1	0.4174 ± 0.0277	0.3559 ± 0.0299
	3	2	0.4263 ± 0.0308	0.3616 ± 0.0246

Fonte: Elaboração própria (2023).

Durante os testes anteriores, foi observado que, mesmo utilizando a técnica *Spe-*

cAugment como *data augmentation*, a performance dos modelos caíam — em alguns casos de forma drástica — nos dados de teste. Sendo assim, foram realizados experimentos, cujos resultados estão demonstrados na Tabela 8, com o melhor modelo obtido nos experimentos anteriores e utilizando outras três técnicas de *data augmentation*: *mixup* (ZHANG *et al.*, 2017), *Cutmix* (YUN *et al.*, 2019) e *SpecMix* (KIM; HAN; KO, 2021). Nela, é possível perceber que nenhuma das outras técnicas superou o resultado obtido com a técnica de *SpechAugment*.

Tabela 8 – Resultado dos experimentos com diferentes técnicas de *data augmentation*.

Ordem	***F1-Score* Validação**	***F1-Score* Teste**
SpecAugment	**0.5532 ± 0.08**	**0.4931 ± 0.0886**
mixup	0.5088 ± 0.0409	0.4009 ± 0.0267
cutmix	0.4722 ± 0.038	0.4068 ± 0.0398
SpecMix	0.4783 ± 0.0556	0.4153 ± 0.0252

Fonte: Elaboração própria (2023).

O melhor modelo obtido na etapa de experimentações, descrita na subseção anterior, foi treinado nas bases EMODB, RAVDESS e SAVEE — utilizando os mesmos critérios de divisão da base estabelecidos na base da CORAA. O melhor resultado conquistado em cada base pode ser visualizado na Tabela 9. Nela, é possível perceber que o modelo teve um resultado bastante satisfatório nos conjuntos de teste e validação da CORAA e EMODB, respectivamente, apresentando um maior ROC-AUC na base EMODB do que na CORAA — indicando que o modelo consegue diferenciar melhor as classes. Já para os conjuntos de validação do RAVDESS e SAVEE os resultados alcançados foram medianos para o *F1-Score macro* e para a acurácia, porém ótimo para a métrica ROC-AUC — indicando que, apesar da performance geral não ter sido boa, o modelo consegue distinguir bem entre algumas classes. A baixa performance nessas duas bases pode ser um indicativo da presença de uma alta complexidade e uma grande curva de aprendizado para ambos conjuntos, mostrando que somente a análise dos áudios não é suficiente, sendo necessário a utilização dos vídeos — que estão presentes nas bases — como estratégia multimodal.

Tabela 9 – Resultados do melhor modelo nas bases de dados.

Base	**Acurácia**	***F1-Score macro***	**ROC-AUC**
CORAA	0.7954	0.5663	0.7217
EMODB	0.8037	0.7635	0.9074
RAVDESS	0.5972	0.578	0.8678
SAVEE	0.6042	0.5643	0.8292

Fonte: Elaboração própria (2023).

O cenário inferido na tabela anterior pode ser validado através da matriz de confusão dos modelos na Figura 26. Nela, é possível notar que na base da CORAA o modelo tem uma ótima performance para áudios neutros, entretanto não possui um bom desempenho nas classes minoritárias que contém emoção. Isso pode ser explicado por meio da Figura 16, podendo ser visto que os áudios são bastante ruidosos e em alguns deles há a presença de diferentes gêneros, que pode afetar o desempenho do modelo. Já no conjunto EMODB, o modelo teve uma excelente performance em praticamente todas as emoções, cujas piores são medo e nojo. No conjunto SAVEE o modelo consegue distinguir bem quando não há presença de emoção e em algumas emoções, porém ainda tem um desempenho baixo para as outras — especialmente para medo e tristeza. Por fim, o modelo no conjunto RAVDESS tem uma boa performance para algumas emoções — como raiva, nojo, surpresa e calma — e baixa para outras — como tristeza, medo, felicidade e neutro. É interessante notar que para as três últimas bases o modelo apresentou dificuldade em reconhecer as emoções de medo e tristeza.

Figura 26 – Matriz de confusão do modelo nas diferentes bases de dados.

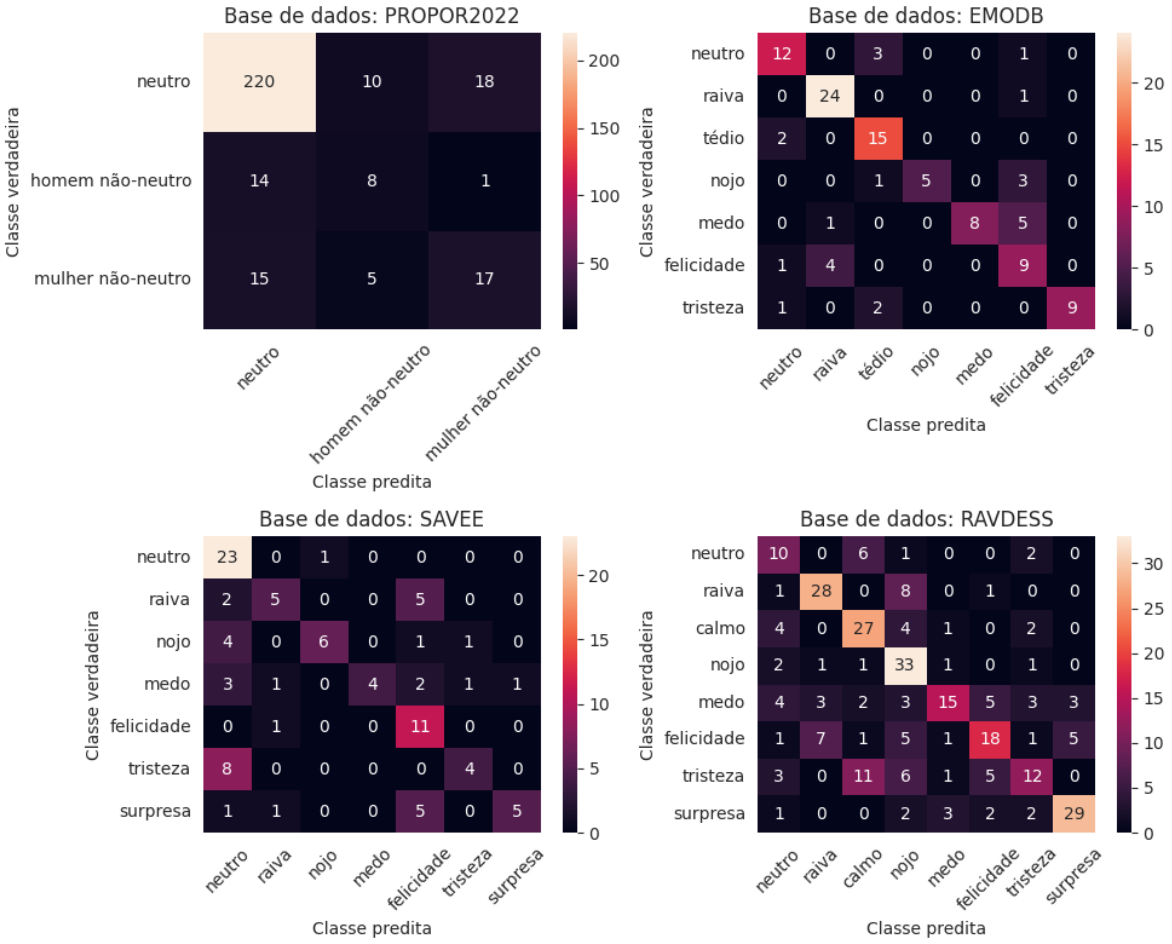

Fonte: Elaboração própria (2023).

Os resultados do melhor modelo obtido para as diferentes bases de dados, apre-

sentados na Tabela 9, foram comparados com os modelos que alcançaram os melhores resultados nos estudos encontrados no mapeamento sistemático (referido no Capítulo 3) e outros da literatura que foram coletados manualmente, não limitando a apenas aqueles que utilizam TW. Os resultados podem ser vistos na Tabela 10, cujos resultados reportados na base da CORAA aplicaram a métrica *F1-Score macro* e para as demais bases foi aplicada a acurácia sem balanceamento. Nela, é possível observar que o modelo conquistou um ótimo resultado no conjunto de dados CORAA, obtendo o segundo melhor resultado geral, o melhor resultado quando considerado aqueles que não utilizam bases e fontes externas e superando os dois modelos-base disponibilizados — descritos em (MARCACINI; JUNIOR; CASANOVA, 2022). Já para os outros conjuntos de dados, existe uma divergência entre os dados usados, o modo de treinamento ou as classes utilizadas, dificultando a comparação entre os resultados. Posto isso, no conjunto EMODB, o modelo obteve uma performance próxima das melhores, principalmente daqueles que usufruíram das mesmas classes utilizadas no presente trabalho. Apesar dos resultados medianos alcançados nos conjuntos SAVEE e RAVDESS, ao comparar com outros estudos da literatura que usam as mesmas classes e dados, é notável perceber que os resultados obtidos estão no mesmo nível, ou até melhores, que desses trabalhos — em especial o conjunto SAVEE, cujos humanos tiveram um desempenho de 0.665 de acurácia ao utilizarem somente os dados de áudio (HAIDER *et al.*, 2021).

Tabela 10 – Comparação dos resultados com outros trabalhos da literatura.

Trabalho	**CORAA**	**EmoDB**	**RAVDESS**	**SAVEE**	**Observação**
(TANMOY *et al.*, 2018)	-	0.809	0.771	-	Treina o modelo usando duas classes por vez.
(AGHAJANI; AFRAKOTI, 2020)	-	**0.891**	0.851	**0.871**	Só utiliza as classes de felicidade, tristeza, neutro e raiva para as bases. Além disso, só utiliza áudios de homem na SAVEE.
(KODURU; VALIVETI; BUDATI, 2020)	-	-	0.85	-	Só utiliza as classes de felicidade, tristeza, neutro e raiva.
(NUGROHO; FUADIYAH, 2022)	-	-	**0.98**	-	Só usa os áudios de normal intensidade.
(MENG *et al.*, 2021)	-	*0.823	-	-	-
(SEKKATE *et al.*, 2019)	-	*0.823	-	-	-
(HUANG *et al.*, 2019)	-	0.866	-	-	Não usa a classe de nojo.
(GAUY; FINGER, 2022)	**0.728**	-	-	-	-
(SALVES *et al.*, 2022)	0.535	-	-	-	-
(SCARANTI *et al.*, 2022)	0.509	-	-	-	-
(PERIN; MATSUBARA, 2022)	0.525	-	-	-	-
(SHEGOKAR; SIRCAR, 2016)	-	-	*0.601	-	Só utiliza os áudios de homem.
(ZENG *et al.*, 2019)	-	-	*0.645	-	-
(VASQUEZ-CORREA *et al.*, 2016)	-	-	-	*0.473	-
(JIANG *et al.*, 2019)	-	*0.845	-	*0.594	-
(HAIDER *et al.*, 2021)	-	*0.769	-	*0.423	-
Presente trabalho	0.566	0.804	0.578	0.604	-

*Os resultados foram obtidos por meio da abordagem de independência do locutor.
Fonte: Elaboração própria (2023).

6 CONCLUSÃO

O principal objetivo deste trabalho foi desenvolver uma solução por meio da utilização de um algoritmo de aprendizado profundo em conjunto com a TW na tarefa de reconhecimento de emoção da fala usando a base de dados CORAA e usufruindo das bases EMODB, SAVEE e RAVDESS — que foram utilizadas na maioria dos trabalhos encontrados no mapeamento sistemática, abordado no Capítulo 3 — para validar a solução desenvolvida.

Ao longo do desenvolvimento do trabalho foram observados alguns desafios:

- Pequena quantidade de trabalhos relacionados encontrados durante o desenvolvimento do mapeamento sistemático, principalmente aqueles que utilizam algoritmo de aprendizado profundo;
- O conjunto de dados CORAA foi lançado recentemente e foi pouco explorado na literatura;
- Além de ser uma base de fala natural, o CORAA apresenta outros tipos de desafios, como: a subtarefa indireta de identificação do gênero do falante, as classes com emoção serem desbalanceadas (conforme visto na Figura 15), a ocorrência de pessoas de diferentes gêneros no mesmo áudio, a sobreposição de vozes, presença de ruídos e vozes em sequência (conforme demonstrado na Figura 16).

Apesar dos desafios, a solução proposta — composta de um modelo com arquitetura baseada na RNAP proposta por (KONG *et al.*, 2020), *SpecAugment* como técnica de *data augmentation* e a utilização da TDW — alcançou um bom resultado na base CORAA com aproximadamente 0.566 de *F1-Score*, obtendo a segunda melhor performance geral e a melhor performance considerando apenas aqueles que utilizaram somente os dados da CORAA durante o desenvolvimento do modelo. Ademais, para a EMODB, SAVEE e RAVDESS, a solução quando comparada aos estudos da literatura que trabalharam com as mesmas classes e áudios nas bases apresentou um bom desempenho em todos os conjuntos, obtendo uma acurácia de aproximadamente 0.804, 0.604 e 0.578 nas bases, respectivamente (é importante reforçar que a divergência entre os dados usados, o modo de treinamento ou as classes utilizadas dos outros trabalhos dificulta a comparação dos resultados). Posto isso, a utilização da TW em conjunto com um algoritmo de aprendizado profundo no reconhecimento de emoção da fala é promissora. Além disto, até o presente momento — e com a busca conduzida no mapeamento sistemático — não foram encontrados outros estudos na literatura que utilizaram a TW em conjuntos de dados de fala natural,

principalmente em uma base com falas em português do Brasil, abrindo uma vasta gama de possíveis trabalhos a serem explorados no futuro.

Embora o resultado conquistado neste trabalho tenha sido satisfatório, ele ainda pode ser expandido e aprimorado de inúmeras maneiras. Todavia, uma clara limitação da solução desenvolvida é não ser capaz de fazer o reconhecimento de emoções em tempo real, necessitando do áudio inteiro para realizar a inferência. Para trabalhos futuros seria interessante explorar outras técnicas de *data augmentation*, que possam funcionar melhor com a TW. No que diz respeito ao pré-processamento dos dados, seria interessante explorar técnicas e modelos visando melhorar a qualidade dos áudios, principalmente em bases de falas naturais, como, por exemplo, a realização de novos testes com outros algoritmos de detecção de atividade de voz. No que se refere a TW, seria interessante explorar outras famílias de *Wavelet*, variar o seu tamanho e utiliza-lá com outras abordagens (como em (TANMOY *et al.*, 2018), (MENG *et al.*, 2021) e (KODURU; VALIVETI; BUDATI, 2020), olha ela é aplicada diretamente no áudio bruto e extraídos medidas estatísticas dos seus coeficientes) ou com outras características ao invés do espectrograma na escala mel (como MFCC e espectrograma, por exemplo). Em relação às bases de dados, seria interessante testar com outras bases de dados diferentes — principalmente as de fala natural — e uma abordagem multimodal para os conjuntos SAVEE e RAVDESS. Por fim, também seria interessante executar os experimentos mais vezes a fim de obter um resultado mais preciso, testar outros modelos de aprendizado de profundo — ou até mesmo os algoritmos de aprendizado de máquina — e utilizar ferramentas para otimizar o processo de variação de parâmetros da TW e os hiper-parâmetros dos modelos, como o *Optuna* (AKIBA *et al.*, 2019) e o *HyperOpt* (BERGSTRA; YAMINS; COX, 2013).

REFERÊNCIAS

AGHAJANI, K.; AFRAKOTI, I. E. P. Speech emotion recognition using scalogram based deep structure. **International Journal of Engineering**, Materials and Energy Research Center, v. 33, n. 2, p. 285–292, 2020.

AGHDAM, H. H.; HERAVI, E. J. *et al.* Guide to convolutional neural networks. **New York, NY: Springer**, Springer, v. 10, n. 978-973, p. 51, 2017.

AKIBA, T. *et al.* Optuna: A next-generation hyperparameter optimization framework. *In*: **Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [*S.l.: s.n.*], 2019.

ALBAWI, S.; MOHAMMED, T. A.; AL-ZAWI, S. Understanding of a convolutional neural network. *In*: IEEE. **2017 international conference on engineering and technology (ICET)**. [*S.l.: s.n.*], 2017. v. 5, p. 1–6.

ARAKI, N. The origin of language. **Bull. Hiroshima Inst. Tech. Research Vol**, v. 52, p. 7–13, 2018.

BADSHAH, A. M. *et al.* Speech emotion recognition from spectrograms with deep convolutional neural network. *In*: **2017 international conference on platform technology and service (PlatCon)**. [*S.l.: s.n.*]: IEEE, 2017. p. 1–5.

BERGSTRA, J.; YAMINS, D.; COX, D. Making a science of model search: Hyperparameter optimization in hundreds of dimensions for vision architectures. *In*: PMLR. **International conference on machine learning**. [*S.l.: s.n.*], 2013. p. 115–123.

BRACEWELL, R. N.; BRACEWELL, R. N. **The Fourier transform and its applications**. [*S.l.: s.n.*]: McGraw-Hill New York, 1986. v. 31999.

BURKHARDT, F. *et al.* A database of german emotional speech. *In*: **Interspeech**. [*S.l.: s.n.*], 2005. v. 5, p. 1517–1520.

CHOMSKY, N. **Language and problems of knowledge: The Managua lectures**. [*S.l.: s.n.*]: MIT press, 1987. v. 16.

DARWIN, C. **The descent of man, and selection in relation to sex**. [*S.l.: s.n.*]: Murray, 1888. v. 1.

FENG, T.; YANG, S. Speech emotion recognition based on lstm and mel scale wavelet packet decomposition. *In*: **Proceedings of the 2018 International Conference on Algorithms, Computing and Artificial Intelligence**. [*S.l.: s.n.*], 2018. p. 1–7.

FITCH, W. T. The evolution of speech: a comparative review. **Trends in cognitive sciences**, Elsevier, v. 4, n. 7, p. 258–267, 2000.

GAO, R. X. *et al.* Wavelet packet transform. **Wavelets: Theory and Applications for Manufacturing**, Springer, p. 69–81, 2011.

GAUY, M. M.; FINGER, M. Pretrained audio neural networks for speech emotion recognition in portuguese. **arXiv preprint arXiv:2210.14716**, 2022.

GOMES, D. d. S. Inteligência artificial: conceitos e aplicações. **Olhar Científico. v1**, n. 2, p. 234–246, 2010.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [*S.l.: s.n.*]: MIT Press, 2016. http://www.deeplearningbook.org.

GUIDO, R. C. *et al.* Cwt x dwt x dtwt x sdtwt: Clarifying terminologies and roles of different types of wavelet transforms. **International Journal of Wavelets, Multiresolution and Information Processing**, World Scientific, v. 18, n. 06, p. 2030001, 2020.

GUO, T. *et al.* A review of wavelet analysis and its applications: Challenges and opportunities. **IEEE Access**, IEEE, v. 10, p. 58869–58903, 2022.

HAIDER, F. *et al.* Emotion recognition in low-resource settings: An evaluation of automatic feature selection methods. **Computer Speech & Language**, Elsevier, v. 65, p. 101119, 2021.

HIRSCHBERG, J.; MANNING, C. D. Advances in natural language processing. **Science**, American Association for the Advancement of Science, v. 349, n. 6245, p. 261–266, 2015.

HUANG, Y. *et al.* Feature fusion methods research based on deep belief networks for speech emotion recognition under noise condition. **Journal of ambient intelligence and humanized computing**, Springer, v. 10, p. 1787–1798, 2019.

ISSA, D.; DEMIRCI, M. F.; YAZICI, A. Speech emotion recognition with deep convolutional neural networks. **Biomedical Signal Processing and Control**, Elsevier, v. 59, p. 101894, 2020.

JANIESCH, C.; ZSCHECH, P.; HEINRICH, K. Machine learning and deep learning. **Electronic Markets**, Springer, v. 31, n. 3, p. 685–395, 2021.

JIANG, P. *et al.* Parallelized convolutional recurrent neural network with spectral features for speech emotion recognition. **IEEE Access**, IEEE, v. 7, p. 90368–90377, 2019.

KEELE, S. *et al.* **Guidelines for performing systematic literature reviews in software engineering**. [*S.l.: s.n.*]: Technical report, ver. 2.3 ebse technical report. ebse, 2007.

KIM, G.; HAN, D. K.; KO, H. Specmix: A mixed sample data augmentation method for training withtime-frequency domain features. **arXiv preprint arXiv:2108.03020**, 2021.

KODURU, A.; VALIVETI, H. B.; BUDATI, A. K. Feature extraction algorithms to improve the speech emotion recognition rate. **International Journal of Speech Technology**, Springer, v. 23, n. 1, p. 45–55, 2020.

KONAR, A.; CHAKRABORTY, A. **Emotion recognition: A pattern analysis approach**. [*S.l.: s.n.*]: John Wiley & Sons, 2015.

KONG, Q. *et al.* Panns: Large-scale pretrained audio neural networks for audio pattern recognition. **IEEE/ACM Transactions on Audio, Speech, and Language Processing**, IEEE, v. 28, p. 2880–2894, 2020.

LALITHA, S. *et al.* Speech emotion recognition using dwt. *In*: IEEE. **2015 IEEE International Conference on Computational Intelligence and Computing Research (ICCIC)**. [*S.l.: s.n.*], 2015. p. 1–4.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, Nature Publishing Group UK London, v. 521, n. 7553, p. 436–444, 2015.

LEE, D. T.; YAMAMOTO, A. Wavelet analysis: theory and applications. **Hewlett Packard journal**, HEWLETT PACKARD, v. 45, p. 44–44, 1994.

LIM, W.; JANG, D.; LEE, T. Speech emotion recognition using convolutional and recurrent neural networks. *In*: IEEE. **2016 Asia-Pacific signal and information processing association annual summit and conference (APSIPA)**. [*S.l.: s.n.*], 2016. p. 1–4.

LIU, T. *et al.* Implementation of training convolutional neural networks. **arXiv preprint arXiv:1506.01195**, 2015.

LIVINGSTONE, S. R.; RUSSO, F. A. The ryerson audio-visual database of emotional speech and song (ravdess): A dynamic, multimodal set of facial and vocal expressions in north american english. **PloS one**, Public Library of Science, v. 13, n. 5, 2018.

MARCACINI, R. M.; JUNIOR, A. C.; CASANOVA, E. Overview of the automatic speech recognition for spontaneous and prepared speech & speech emotion recognition in portuguese (se&r) shared-tasks at propor 2022. *In*: **Proceedings**. [*S.l.: s.n.*], 2022.

MENG, H. *et al.* Speech emotion recognition using wavelet packet reconstruction with attention-based deep recurrent neutral networks. **Bulletin of the Polish Academy of Sciences. Technical Sciences**, Polska Akademia Nauk. Czytelnia Czasopism PAN, v. 69, n. 1, 2021.

NUGROHO, H.; FUADIYAH, R. N. N. Development of speech emotion recognition system based on discrete wavelet transform (dwt) and voice segmentation. **International Journal on Electrical Engineering and Informatics**, School of Electrical Engineering and Informatics, Bandung Institute of . . . , v. 14, n. 3, p. 593–607, 2022.

O'SHEA, K.; NASH, R. An introduction to convolutional neural networks. **arXiv preprint arXiv:1511.08458**, 2015.

PARK, D. S. *et al.* Specaugment: A simple data augmentation method for automatic speech recognition. **arXiv preprint arXiv:1904.08779**, 2019.

PASZKE, A. *et al.* Pytorch: An imperative style, high-performance deep learning library. *In*: **Advances in Neural Information Processing Systems 32**. Curran Associates, Inc., 2019. p. 8024–8035. Available at: http://papers.neurips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library.pdf.

PERIN, E. L. S.; MATSUBARA, E. T. Transductive ensemble learning with graph neural network for speech emotion recognition. 2022.

PETERSEN, K. *et al.* Systematic mapping studies in software engineering. *In*: **12th International Conference on Evaluation and Assessment in Software Engineering (EASE) 12**. [*S.l.: s.n.*], 2008. p. 1–10.

PLUTCHIK, R. A general psychoevolutionary theory of emotion. *In*: **Theories of emotion**. [*S.l.: s.n.*]: Elsevier, 1980. p. 3–33.

POLIKAR, R. *et al.* **The wavelet tutorial**. 1996.

RAMAKRISHNAN, S.; EMARY, I. M. E. Speech emotion recognition approaches in human computer interaction. **Telecommunication Systems**, Springer, v. 52, p. 1467–1478, 2013.

RESEARCH, G. **Google Colaboratory**. 2018. https://colab.research.google.com/notebooks/intro.ipynb?utm_source=scs-index. Acessado em 2023-07-06.

RISSATO, P. H. D. G.; MACEDO, A. A. Sofiafala: Software inteligente de apoio à fala. *In*: SBC. **Anais Estendidos do XXVII Simpósio Brasileiro de Sistemas Multimídia e Web**. [*S.l.: s.n.*], 2021. p. 91–94.

SALVES, C. *et al.* Transfer learning and data augmentation techniques applied to speech emotion recognition in se&r 2022. 2022.

SCARANTI, A. *et al.* Speech emotion recognition in portuguese for sofiafala: Ser sofiafala. 2022.

SEKKATE, S. *et al.* An investigation of a feature-level fusion for noisy speech emotion recognition. **Computers**, MDPI, v. 8, n. 4, 2019.

SHEGOKAR, P.; SIRCAR, P. Continuous wavelet transform based speech emotion recognition. *In*: IEEE. **2016 10th International conference on signal processing and communication systems (ICSPCS)**. [*S.l.: s.n.*], 2016. p. 1–8.

SIFUZZAMAN, M.; ISLAM, M. R.; ALI, M. Z. Application of wavelet transform and its advantages compared to fourier transform. Vidyasagar University, Midnapore, West-Bengal, India, 2009.

TANMOY, R. *et al.* Introducing new feature set based on wavelets for speech emotion classification. *In*: **2018 IEEE applied signal processing conference (ASPCON)**. [*S.l.: s.n.*]: IEEE, 2018. p. 124–128.

VASQUEZ-CORREA, J. C. *et al.* Wavelet-based time-frequency representations for automatic recognition of emotions from speech. *In*: VDE. **Speech Communication; 12. ITG Symposium**. [*S.l.: s.n.*], 2016. p. 1–5.

VLASENKO, B. *et al.* Combining frame and turn-level information for robust recognition of emotions within speech. *In*: . [*S.l.: s.n.*], 2007. p. 2249–2252.

WANI, T. M. *et al.* A comprehensive review of speech emotion recognition systems. **IEEE Access**, IEEE, v. 9, p. 47795–47814, 2021.

YUN, S. *et al.* Cutmix: Regularization strategy to train strong classifiers with localizable features. *In*: **Proceedings of the IEEE/CVF international conference on computer vision**. [*S.l.: s.n.*], 2019. p. 6023–6032.

ZENG, Y. *et al.* Spectrogram based multi-task audio classification. **Multimedia Tools and Applications**, Springer, v. 78, p. 3705–3722, 2019.

ZHANG, H. *et al.* mixup: Beyond empirical risk minimization. **arXiv preprint arXiv:1710.09412**, 2017.

ZHOU, Z.-H. **Machine learning**. [*S.l.: s.n.*]: Springer Nature, 2021.